

TRƯỜNG ĐẠI HỌC THỦY LỢI

KHOA CÔNG NGHỆ THÔNG TIN



**BÁO CÁO BÀI TẬP LỚN HỌC PHẦN
TÍNH TOÁN MỀM**

ĐỀ TÀI: Xây dựng hệ Neuro-Fuzzy thích nghi (ANFIS) dự báo điện năng tiêu thụ hộ gia đình dựa trên thông tin người dùng, thiết bị, thời gian, vị trí và yếu tố khí tượng.

Giảng viên phụ trách môn học: Th.S Trần Mạnh Tuấn

Nhóm thực hiện: Nhóm 2

Thành viên nhóm:

Nguyễn Ngọc Long 2251162063

Nguyễn Phúc Nguyên 2251162091

Hà Nội, tháng 6 năm 2026

Mục lục

LỜI NÓI ĐẦU	1
MÔ TẢ ĐỀ TÀI	2
1. Tên đề tài	2
2. Mục tiêu tổng quát	2
3. Đầu vào và đầu ra của hệ thống	2
4. Phạm vi thực hiện	2
5. Kết quả mong đợi	3
CHƯƠNG 1. Giới thiệu bài toán	4
1. Đặt vấn đề	4
2. Mục tiêu của đề tài	4
3. Đối tượng và phạm vi nghiên cứu	5
4. Phương pháp thực hiện (Workflow)	5
5. Cấu trúc dữ liệu và kết quả	7
6. Bố cục báo cáo	7
CHƯƠNG 2. Cơ sở lý thuyết	8
1. Bài toán dự báo phụ tải điện theo chuỗi thời gian	8
2. Đặc trưng đầu vào	8
3. Tiền xử lý dữ liệu	9
4. Logic mờ	9
5. Mạng nơ-ron và mô hình Neuro-Fuzzy	10
6. Hệ suy diễn Neuro-Fuzzy thích nghi ANFIS	10
6.1. Năm lớp của ANFIS	10
7. Các mô hình so sánh	11
7.1. Linear Regression	12
7.2. Decision Tree Regressor	12
7.3. Random Forest Regressor	12
7.4. XGBoost Regressor	12
8. Các độ đo đánh giá	13

8.1. MAE	13
8.2. RMSE	13
8.3. MAPE	13
8.4. Hệ số xác định R^2	13
CHƯƠNG 3. Dữ liệu và tiền xử lý dữ liệu	14
1. Nguồn dữ liệu	14
1.1. Dữ liệu thời tiết	14
1.2. Dữ liệu phụ tải điện	14
1.3. Cấu trúc bộ dữ liệu	15
2. Khám phá dữ liệu	16
2.1. Phân bố phụ tải điện	16
2.2. Biến động phụ tải điện theo thời gian	17
2.3. Phụ tải điện trung bình theo giờ	18
2.4. Phụ tải điện theo hồ sơ hộ gia đình	18
2.5. Phân tích tương quan giữa các thuộc tính	19
3. Thiết kế đặc trưng	20
3.1. Đặc trưng thời gian	21
3.2. Đặc trưng hành vi sử dụng điện	21
3.3. Đặc trưng thời tiết	22
3.4. Đặc trưng phụ tải lịch sử	22
4. Tiền xử lý dữ liệu	22
4.1. Kiểm tra dữ liệu thiếu và dữ liệu trùng lặp	23
4.2. Tạo nhãn dự báo	24
4.3. Phân chia tập dữ liệu	24
4.4. Chuẩn hóa dữ liệu	24
4.5. Xây dựng Core Dataset	25
4.6. Xây dựng Extended Dataset	25
CHƯƠNG 4. Thiết kế và triển khai mô hình ANFIS	27
1. Mục tiêu triển khai	27
2. Đầu vào, đầu ra và phạm vi mô hình	27
3. Kiến trúc mô hình	28
4. Sinh luật mờ	28
5. Huấn luyện mô hình	29
6. Suy diễn và chuyển ngược đơn vị	30
7. Đánh giá và lưu artifact	30
CHƯƠNG 5. Thực nghiệm và đánh giá mô hình	33

1. Môi trường thực nghiệm	33
2. Thiết lập thực nghiệm	33
3. Các mô hình so sánh	34
4. Kết quả thực nghiệm cho dự báo 1 giờ tới	35
5. Kết quả thực nghiệm cho dự báo 24 giờ tới	37
6. So sánh và thảo luận kết quả	38
7. Nhận xét chung	39
TỔNG KẾT	40
TÀI LIỆU THAM KHẢO	41
DANH MỤC THUẬT NGỮ VÀ VIẾT TẮT	44

LỜI NÓI ĐẦU

Trong bối cảnh nhu cầu sử dụng điện sinh hoạt ngày càng biến động theo thời tiết, lịch sinh hoạt và thói quen sử dụng thiết bị, dự báo phụ tải điện ngắn hạn có ý nghĩa quan trọng đối với quản lý năng lượng hộ gia đình. Một dự báo sát thực tế giúp người dùng chủ động điều chỉnh hành vi tiêu thụ điện, đồng thời hỗ trợ các hệ thống quản lý điện xây dựng kế hoạch vận hành ổn định hơn.

Đề tài “Xây dựng hệ Neuro-Fuzzy thích nghi (ANFIS) dự báo phụ tải điện hộ gia đình cho hai mốc 1 giờ và 24 giờ tới” được thực hiện nhằm nghiên cứu khả năng kết hợp giữa logic mờ và mạng nơ-ron trong bài toán dự báo chuỗi thời gian. Hai mốc dự báo được lựa chọn vì có ý nghĩa sử dụng khác nhau: dự báo 1 giờ tới phục vụ phản ứng nhanh trong ngày, còn dự báo 24 giờ tới hỗ trợ lập kế hoạch tiêu thụ điện cho ngày kế tiếp.

Trong báo cáo này, nhóm trình bày cơ sở lý thuyết của ANFIS, quy trình xây dựng dữ liệu phụ tải điện theo giờ, thiết kế đặc trưng thời gian – thời tiết – hành vi, tiền xử lý dữ liệu, huấn luyện mô hình và đánh giá kết quả cho hai horizon 1h và 24h. Dữ liệu được tổ chức theo cấu trúc rõ ràng gồm nhóm Core Features dành cho ANFIS và Extended Features dành cho các mô hình so sánh hoặc thí nghiệm mở rộng.

Do dữ liệu thực tế từ công tơ hộ gia đình còn khó thu thập đầy đủ, đề tài sử dụng dữ liệu thời tiết thực tế tại Hà Nội kết hợp với dữ liệu phụ tải được mô phỏng theo các hồ sơ sinh hoạt. Đây là một hướng tiếp cận phù hợp trong phạm vi bài tập lớn, giúp nhóm xây dựng được quy trình hoàn chỉnh từ thu thập dữ liệu, sinh đặc trưng, huấn luyện, đánh giá đến lưu trữ kết quả theo từng mốc dự báo.

Nhóm thực hiện xin chân thành cảm ơn giảng viên phụ trách học phần đã hướng dẫn và góp ý trong quá trình thực hiện đề tài.

Nhóm thực hiện

MÔ TẢ ĐỀ TÀI

1. Tên đề tài

Xây dựng hệ Neuro-Fuzzy thích nghi (ANFIS) dự báo phụ tải điện hộ gia đình cho hai mốc 1 giờ và 24 giờ tới.

2. Mục tiêu tổng quát

Đề tài hướng tới xây dựng một mô hình dự báo phụ tải điện sinh hoạt theo giờ bằng mô hình ANFIS. Với một thời điểm quan sát t , hệ thống dự báo điện năng tiêu thụ của hộ gia đình tại hai mốc tương lai:

- **Dự báo 1 giờ tới:** ước lượng phụ tải tại thời điểm $t + 1$.
- **Dự báo 24 giờ tới:** ước lượng phụ tải tại thời điểm $t + 24$.

Hai đầu ra này giúp đánh giá mô hình ở cả tình huống dự báo rất ngắn hạn và tình huống lập kế hoạch cho ngày kế tiếp. Mô hình sử dụng các đặc trưng về thời tiết, chu kỳ thời gian, mức hiện diện của hộ gia đình và phụ tải trong quá khứ để suy diễn kết quả dự báo.

3. Đầu vào và đầu ra của hệ thống

Nhóm thông tin	Mô tả
Dữ liệu nguồn	Dữ liệu thời tiết theo giờ tại Hà Nội và dữ liệu phụ tải điện hộ gia đình được mô phỏng theo các hồ sơ sinh hoạt.
Đặc trưng Core	<code>apparent_temperature</code> , <code>humidity</code> , <code>hour_sin</code> , <code>hour_cos</code> , <code>occupancy_level</code> , <code>load_lag_24</code> . Đây là nhóm đặc trưng chính dùng cho ANFIS.
Đặc trưng Extended	Các đặc trưng mở rộng về hộ gia đình, thời tiết, chu kỳ ngày/tháng, ngày nghỉ, hành vi sử dụng điện, lag features và rolling features.
Đầu ra	<code>target_1h</code> cho dự báo 1 giờ tới và <code>target_24h</code> cho dự báo 24 giờ tới, đơn vị kWh.
Artifact kết quả	Mô hình, metrics, biểu đồ và file dự báo được lưu riêng trong <code>results/1h/</code> và <code>results/24h/</code> .

Bảng 0.1: Mô tả đầu vào và đầu ra dự kiến của hệ thống

4. Phạm vi thực hiện

Trong phạm vi bài tập lớn, hệ thống tập trung vào dự báo phụ tải điện sinh hoạt theo giờ tại Hà Nội. Dữ liệu thời tiết được lấy theo giờ trong giai đoạn 2021–2025,

sau đó kết hợp với các profile hộ gia đình để mô phỏng chuỗi phụ tải điện. Dữ liệu được chia train/test theo thời gian, chuẩn hóa bằng Min-Max Scaling trên tập train và lưu thành hai nhóm **raw** và **scaled**.

Đề tài chưa sử dụng dữ liệu công tơ điện thực tế từ EVN và chưa xét các yếu tố bất thường ngoài mô phỏng như mất điện diện rộng, thay đổi giá điện theo bậc thang hoặc thay đổi hành vi sinh hoạt đột xuất. Các yếu tố này được xem là hướng mở rộng trong giai đoạn sau.

5. Kết quả mong đợi

- Xây dựng được bộ dữ liệu phụ tải điện theo giờ có đủ đặc trưng thời gian, thời tiết, hành vi và phụ tải trễ.
- Tạo được hai tập dữ liệu cho hai horizon **1h** và **24h**, mỗi horizon có cấu trúc **core** và **extended**.
- Thiết kế và huấn luyện được mô hình ANFIS dạng Sugeno cho bài toán hồi quy phụ tải điện.
- Đánh giá mô hình bằng các độ đo MAE, RMSE, MAPE và hệ số R^2 .
- Lưu kết quả huấn luyện, dự báo, metrics và biểu đồ theo từng horizon, gồm các nhóm **plots**, **metrics**, **models** và **predictions**.

CHƯƠNG 1. GIỚI THIỆU BÀI TOÁN

1. Đặt vấn đề

Điện năng tiêu thụ trong hộ gia đình thay đổi liên tục theo giờ, theo ngày và theo điều kiện thời tiết. Cùng một hộ gia đình có thể tiêu thụ rất ít điện vào ban đêm, tăng mạnh vào giờ nấu ăn, giờ sinh hoạt buổi tối hoặc những thời điểm nhiệt độ cảm nhận cao khiến thiết bị làm mát hoạt động nhiều hơn. Vì vậy, dự báo phụ tải điện sinh hoạt không chỉ là bài toán ước lượng một giá trị kWh, mà còn là bài toán mô hình hóa quan hệ giữa thời gian, thời tiết, mức hiện diện và lịch sử tiêu thụ điện.

Trong đề tài này, bài toán được xác định là dự báo phụ tải điện hộ gia đình tại hai mốc tương lai: 1 giờ tới và 24 giờ tới. Mốc 1 giờ tới phù hợp với các ứng dụng phản ứng nhanh như cảnh báo tiêu thụ bất thường hoặc gợi ý giảm tải trong ngày. Mốc 24 giờ tới phù hợp với lập kế hoạch cho ngày kế tiếp, ví dụ ước lượng nhu cầu điện theo lịch sinh hoạt và điều kiện thời tiết dự báo.

ANFIS được lựa chọn vì mô hình có thể học quan hệ phi tuyến từ dữ liệu giống mạng nơ-ron, đồng thời vẫn giữ khả năng diễn giải thông qua các luật mờ IF-THEN. Đặc điểm này phù hợp với bài toán phụ tải điện, nơi các khái niệm như “nóng”, “ấm”, “giờ cao điểm” hoặc “mức hiện diện cao” thường không có ranh giới tuyệt đối.

2. Mục tiêu của đề tài

Mục tiêu chính của đề tài gồm:

- Nghiên cứu cơ sở lý thuyết về logic mờ, mạng nơ-ron và hệ suy diễn Neuro-Fuzzy thích nghi ANFIS.
- Xây dựng bài toán dự báo phụ tải điện sinh hoạt theo giờ với hai target `target_1h` và `target_24h`.
- Thiết kế bộ đặc trưng phù hợp cho ANFIS, bao gồm thời tiết, chu kỳ giờ trong ngày, mức hiện diện và phụ tải cách thời điểm hiện tại 24 giờ.
- Tổ chức dữ liệu sau tiền xử lý thành các nhóm `raw`, `scaled`, `core`, `extended` để dễ huấn luyện và mở rộng thí nghiệm.
- Huấn luyện, đánh giá và lưu kết quả mô hình riêng cho hai horizon 1h và 24h.

- Đánh giá mô hình bằng các độ đo hồi quy như MAE, RMSE, MAPE và hệ số R^2 .

3. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của đề tài là phụ tải điện sinh hoạt theo giờ của hộ gia đình. Phạm vi triển khai tập trung vào dữ liệu tại Hà Nội, trong đó dữ liệu thời tiết được thu thập theo giờ và dữ liệu phụ tải được mô phỏng từ các profile hộ gia đình khác nhau. Các đặc trưng chính gồm nhiệt độ cảm nhận, độ ẩm, chu kỳ giờ trong ngày, mức hiện diện và phụ tải trễ.

Trong phạm vi bài tập lớn, mô hình chưa sử dụng dữ liệu công tơ thực tế và chưa xét đầy đủ các yếu tố như giá điện bậc thang, thay đổi hành vi đột xuất, lịch đi vắng dài ngày hoặc sự cố điện ngoài mô phỏng. Các yếu tố này có thể được bổ sung khi hệ thống có nguồn dữ liệu thực tế phong phú hơn.

4. Phương pháp thực hiện (Workflow)

Workflow chính thức của dự án

Dự án xây dựng hệ thống dự báo phụ tải điện sinh hoạt sử dụng dữ liệu thời tiết thực tế tại Hà Nội, dữ liệu phụ tải mô phỏng và mô hình ANFIS. Quy trình thực hiện gồm các bước chính sau:

1. Thu thập dữ liệu thời tiết

- Sử dụng Open-Meteo API để lấy dữ liệu thời tiết theo giờ tại Hà Nội giai đoạn 2021–2025.
- Các thuộc tính gồm nhiệt độ, độ ẩm, nhiệt độ cảm nhận, lượng mưa, tốc độ gió và độ che phủ mây.
- Kiểm tra dữ liệu thiếu và thực hiện khám phá dữ liệu ban đầu.

2. Xây dựng dữ liệu phụ tải điện

- Xây dựng các profile hộ gia đình với quy mô và thói quen sinh hoạt khác nhau.
- Sinh đặc trưng thời gian như giờ trong ngày, ngày trong tuần, ngày nghỉ, mùa và mã hóa chu kỳ.
- Sinh đặc trưng hành vi như mức hiện diện, hoạt động bữa ăn, giờ làm việc, giờ ngủ.
- Sinh đặc trưng thời tiết như cooling degree, humid hot, rainy hour.

- Mô phỏng phụ tải điện và tạo anomaly/spike.
- Tạo hai nhãn dự báo `target_1h` và `target_24h`.

3. Tiền xử lý dữ liệu

- Làm sạch dữ liệu và loại bỏ giá trị không hợp lệ.
- Kiểm tra missing values và duplicate rows.
- Chia dữ liệu train/test theo thời gian với mốc train kết thúc trước năm 2025.
- Chuẩn hóa dữ liệu bằng Min-Max Scaling, fit scaler trên tập train.
- Tạo nhóm Core Features dành cho ANFIS và nhóm Extended Features dành cho baseline hoặc thí nghiệm mở rộng.
- Lưu dữ liệu vào các nhóm `raw`, `scaled` và `stats` trong thư mục `processed`.

4. Huấn luyện mô hình

- Huấn luyện ANFIS bằng bộ Core Features đã chuẩn hóa.
- Chạy riêng từng horizon 1h và 24h.
- Sử dụng hàm thuộc Gaussian, hệ luật mờ dạng lưới và hệ quả Sugeno bậc nhất.
- Lưu mô hình vào thư mục `results/{horizon}/models/`.

5. Đánh giá và trực quan hóa

- Sử dụng các metrics MAE, RMSE, MAPE và R^2 .
- Vẽ biểu đồ Actual vs Predicted, phân phối residual và membership functions.
- Lưu metrics, prediction và biểu đồ vào `results/1h/` và `results/24h/`.

6. Kết luận và hướng phát triển

- Đánh giá hiệu quả tổng thể của mô hình.
- Phân tích ưu điểm và hạn chế của ANFIS.
- Đề xuất hướng cải tiến với dữ liệu thực tế EVN, tối ưu fuzzy rules và mở rộng tập đặc trưng.

Workflow tổng quát:

Weather Data Collection → Load Dataset Generation → Data Preprocessing → ANFIS Training → Evaluation & Visualization → Conclusion & Future Work

5. Cấu trúc dữ liệu và kết quả

Để tránh nhầm lẫn giữa hai horizon, dữ liệu và kết quả được tách theo cấu trúc thống nhất:

- Dữ liệu chưa chuẩn hóa: `data/processed/raw/`, gồm `core/` và `extended/`.
- Dữ liệu đã chuẩn hóa: `data/processed/scaled/`, gồm `core/` và `extended/`.
- Thống kê scaler và cấu hình đặc trưng: `data/processed/stats/`.
- Kết quả cho dự báo 1 giờ tới: `results/1h/`.
- Kết quả cho dự báo 24 giờ tới: `results/24h/`.

Trong mỗi thư mục kết quả theo horizon, các artifact được chia tiếp thành `plots`, `metrics`, `models` và `predictions`. Cách tổ chức này giúp quá trình đánh giá, so sánh và tái chạy thí nghiệm rõ ràng hơn.

6. Bố cục báo cáo

Báo cáo gồm các phần chính sau:

- Chương 1 trình bày tổng quan bài toán, mục tiêu, phạm vi và workflow thực hiện.
- Chương 2 trình bày cơ sở lý thuyết về logic mờ, mạng nơ-ron và ANFIS.
- Chương 3 trình bày dữ liệu, thiết kế đặc trưng và quy trình tiền xử lý.
- Chương 4 trình bày thiết kế mô hình ANFIS và quy trình suy diễn.
- Chương 5 trình bày phương pháp thực nghiệm, đánh giá và so sánh mô hình.
- Phần tổng kết trình bày kết luận và định hướng phát triển tiếp theo.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

1. Bài toán dự báo phụ tải điện theo chuỗi thời gian

Dự báo phụ tải điện hộ gia đình là bài toán hồi quy chuỗi thời gian, trong đó mô hình ước lượng điện năng tiêu thụ tại một mốc tương lai dựa trên thông tin đã biết ở thời điểm hiện tại. Gọi $load_t$ là điện năng tiêu thụ tại giờ t , vector đặc trưng đầu vào tại thời điểm t được ký hiệu là $\mathbf{x}_t$.

Trong đề tài này, hệ thống không chỉ dự báo một đầu ra chung mà tách thành hai horizon $h \in \{1h, 24h\}$ nên mô hình cần học:

$$\hat{y}_{(t+1)}^{(h)} = f^{(h)}(\mathbf{x}_t), \quad \hat{y}_{(t+24)}^{(h)} = f^{(h)}(\mathbf{x}_t) \quad (2.1)$$

Trong đó $\hat{y}_{(t+1)}^{(h)}$ là dự báo phụ tải 1 giờ tới, còn $\hat{y}_{(t+24)}^{(h)}$ là dự báo phụ tải 24 giờ tới. Hai bài toán dùng cùng nguyên lý mô hình hóa nhưng có nhãn khác nhau là `target_1h` và `target_24h`. Mốc 1 giờ tới phản ánh khả năng dự báo ngắn hạn gần thời gian thực, còn mốc 24 giờ tới phản ánh khả năng nắm bắt chu kỳ ngày và hỗ trợ lập kế hoạch cho ngày kế tiếp.

2. Đặc trưng đầu vào

Đặc trưng đầu vào cần mô tả được ba nhóm tác động chính tới phụ tải sinh hoạt: điều kiện thời tiết, chu kỳ thời gian và hành vi sử dụng điện. Với mô hình ANFIS, đề tài ưu tiên nhóm Core Features có số chiều vừa phải để tránh số lượng luật mờ tăng quá nhanh.

Đặc trưng	Ý nghĩa
<code>apparent_temperature</code>	Nhiệt độ cảm nhận, phản ánh tác động tổng hợp của thời tiết tới nhu cầu làm mát hoặc sưởi.
<code>humidity</code>	Độ ẩm không khí theo giờ, có thể ảnh hưởng tới cảm giác nóng ẩm và nhu cầu sử dụng thiết bị.
<code>hour_sin, hour_cos</code>	Mã hóa chu kỳ giờ trong ngày bằng sin và cos để mô hình hiểu tính tuần hoàn 24 giờ.
<code>occupancy_level</code>	Mức hiện diện hoặc mức hoạt động của hộ gia đình tại thời điểm quan sát.
<code>load_lag_24</code>	Phụ tải cùng giờ của ngày trước, giúp mô hình học chu kỳ sinh hoạt theo ngày.

Bảng 2.1: Nhóm Core Features dùng cho mô hình ANFIS

Ngoài Core Features, nhóm Extended Features có thể bao gồm lag features,

rolling features, đặc trưng ngày trong tuần, ngày nghỉ, mùa, trạng thái mưa hoặc các biến mô tả profile hộ gia đình. Các đặc trưng mở rộng hữu ích cho thí nghiệm bổ sung hoặc mô hình baseline, nhưng khi đưa vào ANFIS cần cân nhắc vì mỗi biến đầu vào làm tăng số luật mờ và chi phí huấn luyện.

3. Tiền xử lý dữ liệu

Trước khi huấn luyện, dữ liệu cần được kiểm tra missing values, duplicate rows và các điểm anomaly/spike quá bất thường. Với chuỗi thời gian, cách chia train/test phải giữ đúng thứ tự thời gian để tránh rò rỉ thông tin từ tương lai về quá khứ. Trong đề tài, scaler chỉ được fit trên tập train, sau đó áp dụng lại cho cả train và test.

Min-Max Scaling được dùng để đưa các đặc trưng về miền giá trị ổn định:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (2.2)$$

Trong đó $x_{\min}$ và $x_{\max}$ được tính từ tập train. Việc chuẩn hóa giúp các biến như nhiệt độ, độ ẩm, mức hiện diện và phụ tải trễ có thang đo tương đồng hơn khi đi vào mô hình. Dữ liệu sau xử lý được tách thành **raw** và **scaled**, đồng thời chia theo nhóm **core** và **extended**.

4. Logic mờ

Logic mờ cho phép biểu diễn những khái niệm không có ranh giới tuyệt đối như “nóng”, “ấm”, “cao điểm” hoặc “mức hiện diện cao”. Thay vì chỉ thuộc hoặc không thuộc một tập, mỗi giá trị có một độ thuộc nằm trong khoảng $[0, 1]$.

Một hàm thuộc thường dùng trong ANFIS là hàm Gaussian:

$$\mu(x) = \exp\left(-\frac{(x - c)^2}{2\sigma^2}\right) \quad (2.3)$$

Trong đó c là tâm của hàm thuộc và σ điều khiển độ rộng của đường cong. Hàm Gaussian có dạng mợt, phù hợp với các biến liên tục như nhiệt độ cảm nhận, độ ẩm hoặc phụ tải trễ.

Luật mờ có dạng IF-THEN. Ví dụ trong bối cảnh phụ tải hộ gia đình:

Nếu nhiệt độ cảm nhận cao, mức hiện diện cao và phụ tải cùng giờ hôm trước cao thì phụ tải ở mốc dự báo có xu hướng cao.

Các luật như vậy giúp mô hình có khả năng diễn giải tốt hơn so với mạng nơ-ron thuần túy.

5. Mạng nơ-ron và mô hình Neuro-Fuzzy

Mạng nơ-ron nhân tạo có khả năng học quan hệ phi tuyến giữa đầu vào và đầu ra thông qua quá trình tối ưu tham số. Trong bài toán phụ tải điện, quan hệ giữa thời tiết, thời gian, hành vi sinh hoạt và điện năng tiêu thụ thường không tuyến tính, vì vậy mô hình học máy là lựa chọn phù hợp.

Tuy nhiên, mạng nơ-ron thường khó giải thích. Ngược lại, logic mờ dễ diễn giải bằng luật IF-THEN nhưng nếu thiết kế thủ công thì khó tự điều chỉnh tham số theo dữ liệu. Mô hình Neuro-Fuzzy kết hợp hai hướng này: phần mờ biểu diễn tri thức bằng luật, còn phần nơ-ron hỗ trợ học tham số từ dữ liệu.

6. Hệ suy diễn Neuro-Fuzzy thích nghi ANFIS

ANFIS (Adaptive Neuro-Fuzzy Inference System) là mô hình Neuro-Fuzzy dùng kiến trúc nhiều lớp để hiện thực hóa hệ suy diễn mờ. Trong đề tài, ANFIS dạng Sugeno bậc nhất được dùng cho bài toán hồi quy phụ tải điện.

Với một horizon $h \in \{1h, 24h\}$, luật Sugeno thứ i có dạng:

$$R_i : \text{ IF } x_1 \text{ is } A_{i1}, \dots, x_n \text{ is } A_{in} \text{ THEN } f_i^{(h)} = p_{i1}^{(h)} x_1 + \dots + p_{in}^{(h)} x_n + r_i^{(h)} \quad (2.4)$$

Trong đó x_k là đặc trưng đầu vào thứ k , A_{ik} là tập mờ tương ứng, còn $p_{ik}^{(h)}$ và $r_i^{(h)}$ là tham số hệ quả cần học cho horizon h .

6.1. Năm lớp của ANFIS

Lớp 1 – Mờ hóa. Mỗi đầu vào được chuyển thành độ thuộc với các tập mờ:

$$\mu_{A_{ik}}(x_k) = \exp\left(-\frac{(x_k - c_{ik})^2}{2\sigma_{ik}^2}\right) \quad (2.5)$$

Trong đó:

- x_k : biến đầu vào thứ k ;
- A_{ik} : tập mờ thứ i của biến đầu vào x_k ;
- c_{ik} : tâm của hàm thuộc;
- σ_{ik} : tham số điều khiển độ rộng của đường cong (σ_{ik} càng nhỏ, đường cong càng hẹp và dốc; σ_{ik} càng lớn, đường cong càng rộng và phẳng).

Lớp 2 – Lớp luật. Mức kích hoạt của luật i thường được tính bằng tích các độ thuộc:

$$w_i = \prod_{k=1}^n \mu_{A_{ik}}(x_k) \quad (2.6)$$

Lớp 3 – Chuẩn hóa. Mức kích hoạt được chuẩn hóa để tạo trọng số tương đối:

$$\bar{w}_i = \frac{w_i}{\sum_{j=1}^N w_j} \quad (2.7)$$

Trong đó:

- N : tổng số luật mờ trong hệ thống;
- w_i : mức kích hoạt của luật thứ i ;
- $\bar{w}_i$: mức kích hoạt chuẩn hóa của luật thứ i trong quá trình suy diễn;
- $\sum_{j=1}^N w_j$: tổng mức kích hoạt của tất cả các luật, đảm bảo rằng tổng các trọng số chuẩn hóa $\sum_{i=1}^N \bar{w}_i$ bằng 1.

Lớp 4 – Hệ quả Sugeno. Lớp hệ quả Sugeno tính đầu ra cục bộ của từng luật, chưa phải dự báo cuối cùng của mô hình. Mỗi nơ-ron trong lớp này tính giá trị hệ quả $f_i^{(h)}$ của một luật dựa trên mô hình Sugeno bậc nhất:

$$f_i^{(h)} = p_{i1}^{(h)} x_1 + \dots + p_{in}^{(h)} x_n + r_i^{(h)} \quad (2.8)$$

Sau đó, kết quả này được nhân với trọng số chuẩn hóa của luật tương ứng từ lớp chuẩn hóa để tạo ra đầu ra có trọng số:

$$\bar{w}_i f_i^{(h)} = \bar{w}_i (p_{i1}^{(h)} x_1 + \dots + p_{in}^{(h)} x_n + r_i^{(h)}) \quad (2.9)$$

Lớp 5 – Tổng hợp đầu ra. Dự báo cuối cùng là tổng các đầu ra có trọng số:

$$\hat{y}^{(h)} = \sum_{i=1}^N \bar{w}_i f_i^{(h)} \quad (2.10)$$

Trong triển khai thực nghiệm, hai horizon 1h và 24h được huấn luyện và đánh giá riêng. Cách tách này giúp lưu artifact rõ ràng theo `results/1h/` và `results/24h/`, đồng thời cho phép so sánh sai số giữa dự báo rất ngắn hạn và dự báo theo chu kỳ ngày.

7. Các mô hình so sánh

Bên cạnh ANFIS, đề tài sử dụng một số mô hình học máy phổ biến làm baseline để đánh giá khách quan chất lượng dự báo. Khác với ANFIS, các mô hình baseline được huấn luyện trên Extended Dataset nhằm khai thác nhóm đặc trưng mở rộng

về thời tiết, chu kỳ thời gian, hành vi sử dụng điện, đặc trưng trễ và rolling features. Việc so sánh này giúp xác định liệu ANFIS với tập Core Features rút gọn có đạt hiệu quả cạnh tranh so với các mô hình học máy thông dụng hay không.

7.1. Linear Regression

Linear Regression giả định quan hệ giữa các đặc trưng đầu vào và phụ tải điện là tuyến tính. Mô hình học một tổ hợp tuyến tính của các biến đầu vào sao cho sai số bình phương giữa dự báo và giá trị thực tế là nhỏ nhất.

Linear Regression được dùng làm baseline tuyến tính vì dễ triển khai, dễ giải thích và cho biết mức hiệu quả tối thiểu khi chỉ xét quan hệ tuyến tính. Hạn chế chính là khó mô hình hóa các tương tác phi tuyến giữa thời tiết, thời điểm trong ngày và hành vi sử dụng điện.

7.2. Decision Tree Regressor

Decision Tree Regressor chia không gian đặc trưng thành nhiều vùng bằng các điều kiện rẽ nhánh. Mỗi lá của cây tương ứng với một giá trị dự báo hoặc giá trị trung bình của các mẫu huấn luyện thuộc vùng đó.

Mô hình cây quyết định phù hợp làm baseline phi tuyến đơn giản vì có thể học các ngưỡng như giờ cao điểm, mức hiện diện cao hoặc nhiệt độ cảm nhận lớn. Tuy nhiên, cây đơn dễ bị quá khớp nếu không giới hạn độ sâu và kết quả có thể kém ổn định trước biến động dữ liệu.

7.3. Random Forest Regressor

Random Forest Regressor là mô hình ensemble gồm nhiều cây quyết định được huấn luyện trên các mẫu và tập đặc trưng con khác nhau. Dự báo cuối cùng thường là trung bình dự báo của toàn bộ các cây.

Mô hình này được sử dụng vì có khả năng học quan hệ phi tuyến tốt hơn cây đơn và giảm phương sai nhờ cơ chế kết hợp nhiều cây. Điểm mạnh của Random Forest là ổn định trên dữ liệu bảng, nhưng hạn chế là khó diễn giải hơn mô hình tuyến tính hoặc một cây quyết định đơn lẻ.

7.4. XGBoost Regressor

XGBoost Regressor là mô hình boosting, trong đó các cây quyết định được huấn luyện tuần tự để sửa sai cho các cây trước đó. Cơ chế này giúp mô hình tập trung vào những mẫu khó dự báo và thường đạt hiệu quả cao trên dữ liệu dạng bảng.

XGBoost được dùng làm baseline mạnh để so sánh với ANFIS vì có khả năng khai thác tương tác phi tuyến phức tạp giữa các đặc trưng Extended. Hạn chế của mô

hình là có nhiều siêu tham số cần điều chỉnh và khả năng diễn giải trực tiếp thấp hơn ANFIS.

8. Các độ đo đánh giá

Vì đầu ra là điện năng tiêu thụ theo đơn vị kWh, mô hình được đánh giá bằng các metrics hồi quy. Với M mẫu kiểm tra, $y_t^{(h)}$ là giá trị thực tế và $\hat{y}_t^{(h)}$ là giá trị dự báo.

8.1. MAE

$$MAE = \frac{1}{M} \sum_{t=1}^M |y_t^{(h)} - \hat{y}_t^{(h)}| \quad (2.11)$$

MAE cho biết trung bình mô hình dự báo lệch bao nhiêu kWh so với thực tế.

8.2. RMSE

$$RMSE = \sqrt{\frac{1}{M} \sum_{t=1}^M (y_t^{(h)} - \hat{y}_t^{(h)})^2} \quad (2.12)$$

RMSE phạt mạnh các sai số lớn, do đó hữu ích khi cần quan sát các lần dự báo lệch nhiều.

8.3. MAPE

$$MAPE = \frac{100}{M} \sum_{t=1}^M \left| \frac{y_t^{(h)} - \hat{y}_t^{(h)}}{y_t^{(h)}} \right| \quad (2.13)$$

MAPE biểu diễn sai số trung bình theo phần trăm. Khi dùng độ đo này cần đảm bảo $y_t^{(h)}$ khác 0 hoặc có cơ chế xử lý mẫu có giá trị rất nhỏ.

8.4. Hệ số xác định R^2

$$R^2 = 1 - \frac{\sum_{t=1}^M (y_t^{(h)} - \hat{y}_t^{(h)})^2}{\sum_{t=1}^M (y_t^{(h)} - \bar{y})^2} \quad (2.14)$$

R^2 càng gần 1 thì mô hình càng giải thích tốt biến thiên của dữ liệu; nếu $R^2 < 0$, mô hình kém hơn cách dự báo bằng giá trị trung bình.

CHƯƠNG 3. DỮ LIỆU VÀ TIỀN XỬ LÝ DỮ LIỆU

1. Nguồn dữ liệu

Độ chính xác của mô hình dự báo phụ tải điện phụ thuộc đáng kể vào chất lượng và mức độ đại diện của dữ liệu đầu vào. Trong nghiên cứu này, nhóm xây dựng bộ dữ liệu bằng cách kết hợp dữ liệu thời tiết lịch sử của khu vực Hà Nội với dữ liệu phụ tải điện được mô phỏng dựa trên các hồ sơ sinh hoạt điển hình của hộ gia đình. Sự kết hợp này giúp bộ dữ liệu phản ánh đồng thời ảnh hưởng của điều kiện môi trường và hành vi sử dụng điện đến nhu cầu tiêu thụ điện năng.

1.1. Dữ liệu thời tiết

Nhu cầu sử dụng điện của hộ gia đình chịu ảnh hưởng đáng kể bởi các điều kiện thời tiết. Trong những ngày có nhiệt độ cao hoặc độ ẩm lớn, các thiết bị làm mát như quạt điện và điều hòa không khí thường được sử dụng với tần suất nhiều hơn, dẫn đến sự gia tăng của phụ tải điện. Ngược lại, trong điều kiện thời tiết mát mẻ hoặc có mưa, nhu cầu sử dụng điện có thể giảm xuống.

Để phản ánh các yếu tố ảnh hưởng này, đề tài sử dụng dữ liệu thời tiết lịch sử được thu thập từ Open-Meteo Archive API cho khu vực Hà Nội trong giai đoạn từ tháng 01 năm 2021 đến tháng 12 năm 2025 với độ phân giải theo giờ. Bộ dữ liệu bao gồm các thông tin khí tượng có khả năng tác động trực tiếp hoặc gián tiếp đến nhu cầu sử dụng điện của hộ gia đình.

Các thuộc tính thời tiết được sử dụng trong nghiên cứu được trình bày trong Bảng 3.1.

Bảng 3.1: Các thuộc tính thời tiết sử dụng trong nghiên cứu

Thuộc tính	Đơn vị	Ý nghĩa
temperature	°C	Nhiệt độ không khí tại thời điểm quan sát
humidity	%	Độ ẩm tương đối của không khí
apparent_temperature	°C	Nhiệt độ cảm nhận thực tế của con người
rain	mm	Lượng mưa ghi nhận theo giờ
wind_speed	km/h	Tốc độ gió trung bình
cloud_cover	%	Mức độ che phủ của mây trên bầu trời

1.2. Dữ liệu phụ tải điện

Trong thực tế, dữ liệu tiêu thụ điện của hộ gia đình thường khó tiếp cận do các hạn chế liên quan đến quyền riêng tư và khả năng chia sẻ dữ liệu. Vì vậy, trong phạm vi của đề tài, nhóm sử dụng phương pháp mô phỏng phụ tải điện dựa trên

các hồ sơ sinh hoạt điển hình của hộ gia đình.

Mỗi hồ sơ đại diện cho một nhóm người dùng với các đặc điểm sinh hoạt khác nhau về số lượng thành viên, thời gian hiện diện tại nhà và mức độ sử dụng thiết bị điện. Trên cơ sở đó, các mẫu tiêu thụ điện được xây dựng nhằm phản ánh tương đối sát với hành vi sử dụng điện trong thực tế.

Các hồ sơ hộ gia đình được sử dụng để mô phỏng phụ tải điện được trình bày trong Bảng 3.2.

Bảng 3.2: Các hồ sơ hộ gia đình sử dụng trong mô phỏng phụ tải điện

Profile	Đặc điểm
student	Sinh viên sống độc lập, thời gian học tập và sinh hoạt linh hoạt
single_worker	Người đi làm sống một mình, thường vắng nhà vào giờ hành chính
family_3	Gia đình gồm ba thành viên với nhu cầu sử dụng điện ở mức trung bình
family_4_wfh	Gia đình bốn thành viên có người làm việc tại nhà, mức tiêu thụ điện cao hơn các nhóm còn lại

Các hồ sơ trên được sử dụng để tạo ra các mẫu phụ tải điện đa dạng, giúp bộ dữ liệu mô phỏng phản ánh được nhiều kịch bản sử dụng điện khác nhau trong môi trường dân dụng.

1.3. Cấu trúc bộ dữ liệu

Sau quá trình kết hợp dữ liệu thời tiết, dữ liệu phụ tải điện và các bước sinh đặc trưng, bộ dữ liệu cuối cùng bao gồm các nhóm thuộc tính về thời gian, thời tiết, hành vi sử dụng điện và phụ tải lịch sử. Các thuộc tính này được sử dụng làm đầu vào cho quá trình huấn luyện và đánh giá mô hình.

Bảng 3.3 trình bày một số thuộc tính quan trọng trong bộ dữ liệu được sử dụng trong nghiên cứu.

Bảng 3.3: Các thuộc tính chính của bộ dữ liệu

Thuộc tính	Nhóm	Ý nghĩa
datetime	Time	Thời điểm ghi nhận dữ liệu
hour	Time	Giờ trong ngày
day_of_week	Time	Ngày trong tuần
occupancy_level	Behavior	Mức độ hiện diện của các thành viên trong hộ gia đình
apparent_temperature	Weather	Nhiệt độ cảm nhận
humidity	Weather	Độ ẩm không khí
load_lag_1	Load	Phụ tải điện của một giờ trước đó
load_lag_24	Load	Phụ tải điện của cùng thời điểm ngày hôm trước
target_1h	Target	Phụ tải điện cần dự báo sau 1 giờ
target_24h	Target	Phụ tải điện cần dự báo sau 24 giờ


Từ bộ dữ liệu này, nhóm tiến hành thực hiện các bước khám phá dữ liệu, thiết kế đặc trưng và tiền xử lý nhằm xây dựng tập dữ liệu phù hợp cho bài toán dự báo phụ tải điện bằng mô hình ANFIS.

2. Khám phá dữ liệu

Trước khi xây dựng mô hình dự báo, nhóm tiến hành khám phá dữ liệu nhằm đánh giá đặc điểm phân bố của phụ tải điện, xu hướng biến động theo thời gian và mối quan hệ giữa các thuộc tính. Quá trình này giúp xác định những đặc trưng có ý nghĩa và hỗ trợ các bước thiết kế đặc trưng, tiền xử lý dữ liệu ở các phần tiếp theo.

2.1. Phân bố phụ tải điện

Trước hết, nhóm khảo sát phân bố của biến phụ tải điện `load_kwh` trên toàn bộ tập dữ liệu. Đây là biến trung tâm của bài toán, đồng thời là cơ sở để xây dựng các nhãn dự báo `target_1h` và `target_24h`.




Hình 3.1: Phân bố phụ tải điện trong bộ dữ liệu

Hình 3.1 cho thấy phân bố phụ tải điện có dạng lệch phải. Phần lớn các giá trị phụ tải tập trung ở mức tiêu thụ thấp đến trung bình, trong khi các giá trị phụ tải cao xuất hiện với tần suất thấp hơn. Điều này phản ánh đặc điểm sử dụng điện của hộ gia đình, khi phần lớn thời gian mức tiêu thụ điện duy trì ở trạng thái thông thường và chỉ tăng mạnh tại một số khung giờ cao điểm hoặc khi nhiều thiết bị điện được sử dụng đồng thời.

2.2. Biến động phụ tải điện theo thời gian

Để đánh giá xu hướng thay đổi của phụ tải điện theo thời gian, nhóm tiến hành quan sát sự biến thiên của phụ tải điện trong một khoảng thời gian đại diện của tập dữ liệu.



Hình 3.2: Biến động phụ tải điện theo thời gian


Hình 3.2 cho thấy phụ tải điện biến động liên tục theo từng giờ và xuất hiện

các chu kỳ lặp lại theo ngày. Sự dao động này phản ánh tác động đồng thời của nhiều yếu tố như thời tiết, thời điểm trong ngày và hành vi sử dụng điện của các thành viên trong hộ gia đình.

Kết quả cho thấy dữ liệu có tính chu kỳ và tính thời gian rõ rệt, đây là một trong những đặc điểm quan trọng của bài toán dự báo phụ tải điện ngắn hạn.

2.3. Phụ tải điện trung bình theo giờ

Để đánh giá ảnh hưởng của thời gian trong ngày đến nhu cầu sử dụng điện, nhóm tiến hành tính toán giá trị phụ tải điện trung bình tại từng giờ.




Hình 3.3: Phụ tải điện trung bình theo giờ trong ngày

Kết quả thể hiện trong Hình 3.3 cho thấy phụ tải điện thay đổi đáng kể theo từng khung giờ. Mức tiêu thụ điện đạt giá trị cao nhất trong khoảng từ 18 giờ đến 20 giờ, tương ứng với thời điểm các thành viên trong gia đình trở về nhà và sử dụng đồng thời nhiều thiết bị điện sinh hoạt.

Ngược lại, mức tiêu thụ điện thấp hơn vào các khung giờ sáng và đầu giờ chiều. Điều này cho thấy các đặc trưng thời gian đóng vai trò quan trọng trong việc dự báo nhu cầu sử dụng điện.

2.4. Phụ tải điện theo hồ sơ hộ gia đình

Bên cạnh yếu tố thời gian, hành vi sinh hoạt của từng nhóm hộ gia đình cũng ảnh hưởng đáng kể đến mức tiêu thụ điện năng.




Hình 3.4: Phụ tải điện trung bình theo hồ sơ hộ gia đình

Hình 3.4 cho thấy mức phụ tải điện trung bình của từng hồ sơ hộ gia đình. Nhóm family_4_wfh có mức tiêu thụ điện cao nhất do số lượng thành viên lớn và thời gian hiện diện tại nhà nhiều hơn so với các nhóm còn lại.

Trong khi đó, các nhóm student và single_worker có mức tiêu thụ điện thấp hơn do thời gian sử dụng thiết bị điện ít hơn và quy mô hộ gia đình nhỏ hơn. Kết quả này cho thấy việc mô hình hóa hành vi sinh hoạt là cần thiết để nâng cao khả năng dự báo phụ tải điện.

2.5. Phân tích tương quan giữa các thuộc tính

Để đánh giá mối quan hệ giữa các thuộc tính đầu vào và biến phụ tải điện, nhóm sử dụng ma trận tương quan Pearson.



Hình 3.5: Ma trận tương quan giữa các thuộc tính

Hình 3.5 cho thấy các biến `load_lag_1` và `load_lag_24` có hệ số tương quan cao với biến phụ tải điện hiện tại (`load_kwh`). Điều này cho thấy thông tin phụ tải trong quá khứ đóng vai trò quan trọng đối với bài toán dự báo.

Ngoài ra, biến `occupancy_level` cũng có mối tương quan dương tương đối mạnh với phụ tải điện, phản ánh ảnh hưởng của mức độ hiện diện của các thành viên trong hộ gia đình đến nhu cầu sử dụng điện. Trong khi đó, các thuộc tính thời tiết có mức tương quan thấp hơn nhưng vẫn cung cấp thông tin hỗ trợ cho mô hình dự báo.

Từ kết quả phân tích trên, nhóm lựa chọn các thuộc tính có ý nghĩa thực tiễn và khả năng dự báo cao để xây dựng tập đặc trưng đầu vào cho mô hình ANFIS.

3. Thiết kế đặc trưng

Sau khi hoàn thành bước khám phá dữ liệu, nhóm tiến hành xây dựng các đặc trưng đầu vào nhằm mô tả đầy đủ các yếu tố ảnh hưởng đến nhu cầu tiêu thụ điện năng. Quá trình thiết kế đặc trưng đóng vai trò quan trọng trong việc nâng cao khả năng học và dự báo của mô hình ANFIS.

Các đặc trưng được xây dựng dựa trên bốn nhóm thông tin chính gồm đặc trưng thời gian, đặc trưng hành vi sử dụng điện, đặc trưng thời tiết và đặc trưng phụ tải lịch sử.

3.1. Đặc trưng thời gian

Các nghiên cứu về dự báo phụ tải điện cho thấy nhu cầu sử dụng điện có mối liên hệ chặt chẽ với thời điểm trong ngày, ngày trong tuần và mùa trong năm. Vì vậy, nhóm xây dựng các đặc trưng thời gian nhằm mô tả tính chu kỳ của dữ liệu.

Các đặc trưng được sử dụng bao gồm:

- hour: giờ trong ngày.
- day_of_week: ngày trong tuần.
- is_weekend: xác định ngày cuối tuần.
- month: tháng trong năm.
- season: mùa trong năm.

Ngoài ra, để biểu diễn tính tuần hoàn của thời gian, nhóm áp dụng kỹ thuật Cyclic Encoding bằng hàm sin và cos:

$$hour_sin = \sin\left(\frac{2\pi \times hour}{24}\right) \quad (3.1)$$

$$hour_cos = \cos\left(\frac{2\pi \times hour}{24}\right) \quad (3.2)$$

Việc sử dụng biểu diễn sin/cos giúp mô hình hiểu được mối quan hệ tuần hoàn giữa các thời điểm trong ngày, ví dụ 23 giờ và 0 giờ có khoảng cách thời gian rất gần nhau.

3.2. Đặc trưng hành vi sử dụng điện

Bên cạnh các yếu tố thời gian, hành vi sinh hoạt của hộ gia đình cũng ảnh hưởng trực tiếp đến mức tiêu thụ điện năng.

Nhóm xây dựng các đặc trưng mô tả hành vi sử dụng điện gồm:

- occupancy_level: mức độ hiện diện của các thành viên trong gia đình.
- working_hour: thời gian làm việc hoặc học tập.
- meal_activity: thời điểm chuẩn bị và sử dụng bữa ăn.
- evening_peak: giai đoạn cao điểm vào buổi tối.
- usage_period: khoảng thời gian sử dụng điện trong ngày.

Các đặc trưng này giúp mô hình phản ánh tốt hơn sự thay đổi nhu cầu điện năng theo từng nhóm hộ gia đình khác nhau.

3.3. Đặc trưng thời tiết

Dữ liệu thời tiết ban đầu được tiếp tục chuyển đổi thành các đặc trưng có ý nghĩa hơn đối với bài toán dự báo phụ tải điện.

Các đặc trưng được xây dựng bao gồm:

- `cooling_degree`: mức độ nhu cầu làm mát.
- `heating_degree`: mức độ nhu cầu sưởi ấm.
- `humid_hot`: chỉ số kết hợp giữa nhiệt độ và độ ẩm.
- `rainy_hour`: biến biểu diễn thời điểm có mưa.

Những đặc trưng này giúp mô hình phản ánh rõ hơn tác động của điều kiện thời tiết tới hành vi sử dụng điện.

3.4. Đặc trưng phụ tải lịch sử

Đặc điểm quan trọng của bài toán dự báo chuỗi thời gian là giá trị hiện tại thường phụ thuộc vào các giá trị trong quá khứ.


Do đó, nhóm xây dựng các đặc trưng phụ tải lịch sử bao gồm:

- `load_lag_1`: phụ tải điện tại thời điểm trước đó một giờ.
- `load_lag_24`: phụ tải điện tại cùng thời điểm của ngày trước đó.
- `rolling_mean`: giá trị trung bình trượt của phụ tải điện.

Các đặc trưng này cung cấp thông tin về xu hướng tiêu thụ điện trong quá khứ và được kỳ vọng có ảnh hưởng mạnh đến khả năng dự báo của mô hình.

4. Tiền xử lý dữ liệu

Sau khi hoàn thành quá trình xây dựng và khám phá dữ liệu, nhóm tiến hành tiền xử lý dữ liệu nhằm tạo ra các tập dữ liệu phù hợp cho quá trình huấn luyện và đánh giá mô hình. Các bước tiền xử lý bao gồm kiểm tra dữ liệu thiếu, kiểm tra dữ liệu trùng lặp, tạo nhãn dự báo, chia tập dữ liệu theo thời gian và chuẩn hóa dữ liệu.



Hình 3.6: Tổng quan quy trình tiền xử lý dữ liệu

4.1. Kiểm tra dữ liệu thiếu và dữ liệu trùng lặp

Trước khi đưa dữ liệu vào mô hình, nhóm kiểm tra các giá trị thiếu (missing values) và các dòng dữ liệu trùng lặp nhằm đảm bảo tính nhất quán của bộ dữ liệu. Việc kiểm tra này đặc biệt quan trọng đối với dữ liệu chuỗi thời gian, vì các giá trị thiếu hoặc trùng lặp có thể làm sai lệch quá trình tạo đặc trưng trễ và nhãn dự báo.

Kết quả kiểm tra cho thấy bộ dữ liệu sau khi xây dựng không còn giá trị thiếu và không có bản ghi trùng lặp theo cặp `profile_code` và `datetime`. Sau quá trình xử lý, các bản ghi không hợp lệ phát sinh từ quá trình tạo biến trễ và tạo nhãn dự báo được loại bỏ. Nhờ đó, bộ dữ liệu cuối cùng đảm bảo đầy đủ thông tin cần thiết cho quá trình huấn luyện mô hình.

Bảng 3.4: Kết quả kiểm tra chất lượng dữ liệu

Tiêu chí kiểm tra	Kết quả
Số bản ghi trong bộ dữ liệu	175 104
Tổng số giá trị thiếu	0
Số bản ghi trùng lặp theo <code>profile_code</code> và <code>datetime</code>	0
Số bản ghi hợp lệ cho mỗi horizon dự báo	175 104

4.2. Tạo nhãn dự báo

Bài toán trong đề tài được xây dựng với hai mốc dự báo khác nhau gồm dự báo phụ tải điện sau 1 giờ và sau 24 giờ. Do đó, từ biến phụ tải điện gốc `load_kwh`, nhóm tạo ra hai biến mục tiêu:

- `target_1h`: phụ tải điện tại thời điểm sau 1 giờ.
- `target_24h`: phụ tải điện tại thời điểm sau 24 giờ.

Việc xây dựng hai nhãn dự báo này cho phép đánh giá mô hình ở cả bài toán dự báo rất ngắn hạn và bài toán dự báo theo chu kỳ ngày. Trong đó, `target_1h` phản ánh khả năng dự báo gần thời gian thực, còn `target_24h` phản ánh khả năng nắm bắt quy luật lặp lại theo ngày của phụ tải điện.

4.3. Phân chia tập dữ liệu

Do dữ liệu phụ tải điện có bản chất chuỗi thời gian, nhóm không sử dụng phương pháp chia ngẫu nhiên như các bài toán học máy thông thường. Thay vào đó, dữ liệu được chia theo thứ tự thời gian nhằm tránh hiện tượng rò rỉ dữ liệu từ tương lai vào quá trình huấn luyện.

Trong đề tài, dữ liệu giai đoạn từ năm 2021 đến năm 2024 được sử dụng làm tập huấn luyện, trong khi dữ liệu năm 2025 được sử dụng làm tập kiểm tra. Cách chia này giúp đánh giá mô hình trong bối cảnh gần với thực tế hơn, khi mô hình được huấn luyện trên dữ liệu quá khứ và dự báo cho các thời điểm tương lai.

Bảng 3.5: Tóm tắt phân chia dữ liệu sau tiền xử lý

Mốc	Tập	Số dòng	Khoảng thời gian	Mean	Std
1h	All	175 104	2021-01-02 – 2025-12-30 23:00	0.832	0.596
1h	Train	140 160	2021-01-02 – 2024-12-31 23:00	0.835	0.599
1h	Test	34 944	2025-01-01 – 2025-12-30 23:00	0.819	0.587
24h	All	175 104	2021-01-02 – 2025-12-30 23:00	0.831	0.596
24h	Train	140 160	2021-01-02 – 2024-12-31 23:00	0.835	0.599
24h	Test	34 944	2025-01-01 – 2025-12-30 23:00	0.818	0.587

Trong bảng trên, *Mean* và *Std* lần lượt là giá trị trung bình và độ lệch chuẩn của biến mục tiêu tương ứng với từng horizon. Tỷ lệ dữ liệu huấn luyện và kiểm tra xấp xỉ 80%–20%, phù hợp với mục tiêu đánh giá mô hình trên giai đoạn tương lai.

4.4. Chuẩn hóa dữ liệu

Các thuộc tính trong bộ dữ liệu có miền giá trị khác nhau, ví dụ nhiệt độ được đo theo độ C, độ ẩm theo phần trăm, còn phụ tải điện theo kWh. Nếu đưa trực tiếp

các biến này vào mô hình, các thuộc tính có giá trị lớn hơn có thể gây ảnh hưởng không cân bằng đến quá trình học.

Vì vậy, nhóm sử dụng phương pháp Min-Max Scaling để đưa các thuộc tính số về cùng miền giá trị từ 0 đến 1. Công thức chuẩn hóa được biểu diễn như sau:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (3.3)$$

Trong đó, x là giá trị ban đầu, x' là giá trị sau chuẩn hóa, $x_{\min}$ và $x_{\max}$ lần lượt là giá trị nhỏ nhất và lớn nhất của thuộc tính trong tập huấn luyện.

Để tránh rò rỉ dữ liệu, bộ chuẩn hóa chỉ được học trên tập huấn luyện, sau đó áp dụng lại cho cả tập huấn luyện và tập kiểm tra. Cách làm này đảm bảo rằng thông tin từ tập kiểm tra không ảnh hưởng đến quá trình huấn luyện mô hình.

4.5. Xây dựng Core Dataset

Đối với mô hình ANFIS, số lượng đặc trưng đầu vào cần được kiểm soát để tránh số lượng luật mờ tăng quá nhanh. Vì vậy, nhóm xây dựng Core Dataset gồm các đặc trưng quan trọng nhất, có ý nghĩa rõ ràng đối với bài toán dự báo phụ tải điện.

Các đặc trưng trong Core Dataset bao gồm:

- `apparent_temperature`
- `humidity`
- `hour_sin`
- `hour_cos`
- `occupancy_level`
- `load_lag_24`

Nhóm đặc trưng này được lựa chọn nhằm cân bằng giữa khả năng biểu diễn dữ liệu và độ phức tạp của mô hình ANFIS. Trong đó, `apparent_temperature` và `humidity` mô tả ảnh hưởng của thời tiết, `hour_sin` và `hour_cos` biểu diễn chu kỳ thời gian trong ngày, `occupancy_level` phản ánh mức độ hiện diện của hộ gia đình, còn `load_lag_24` cung cấp thông tin phụ tải cùng giờ của ngày hôm trước.

4.6. Xây dựng Extended Dataset

Bên cạnh Core Dataset, nhóm cũng xây dựng Extended Dataset bao gồm tập đặc trưng mở rộng hơn. Tập dữ liệu này được sử dụng cho các mô hình baseline như Linear Regression, Decision Tree, Random Forest và XGBoost, đồng thời phục vụ các thí nghiệm mở rộng.

Extended Dataset bao gồm các đặc trưng về thời gian, thời tiết, hành vi sử dụng điện, phụ tải lịch sử, rolling features và các thông tin mô tả hồ sơ hộ gia đình. Việc xây dựng thêm tập đặc trưng mở rộng giúp nhóm có cơ sở so sánh hiệu quả giữa mô hình ANFIS sử dụng tập đặc trưng rút gọn và các mô hình học máy khác sử dụng tập đặc trưng đầy đủ hơn.

Sau quá trình tiền xử lý, dữ liệu được lưu thành các nhóm riêng biệt theo từng horizon dự báo 1 giờ và 24 giờ, đồng thời tách thành dữ liệu chưa chuẩn hóa và dữ liệu đã chuẩn hóa. Cách tổ chức này giúp quá trình huấn luyện, đánh giá và so sánh mô hình được thực hiện rõ ràng và dễ tái lập.

CHƯƠNG 4. THIẾT KẾ VÀ TRIỂN KHAI MÔ HÌNH ANFIS

1. Mục tiêu triển khai

Chương này trình bày cách thiết kế và triển khai mô hình ANFIS cho bài toán dự báo phụ tải điện hộ gia đình theo giờ. Khác với hướng dự báo điện năng theo tháng, mô hình trong dự án hiện tại làm việc với chuỗi dữ liệu theo giờ và huấn luyện riêng cho hai mốc dự báo:

- 1h: dự báo phụ tải tại giờ kế tiếp, sử dụng nhãn `target_1h`.
- 24h: dự báo phụ tải cùng giờ của ngày kế tiếp, sử dụng nhãn `target_24h`.

Hai mô hình sử dụng cùng kiến trúc ANFIS Core nhưng tách dữ liệu, scaler, kết quả và artifact theo từng horizon. Cách triển khai này giúp việc đánh giá không bị lẫn giữa dự báo rất ngắn hạn và dự báo theo chu kỳ ngày.

2. Đầu vào, đầu ra và phạm vi mô hình

Mô hình ANFIS sử dụng nhóm Core Features đã được chuẩn hóa bằng Min-Max Scaling. Vector đầu vào tại thời điểm t được ký hiệu là:

$$\mathbf{x}_t = [x_{t,1}, x_{t,2}, \dots, x_{t,6}] \quad (4.1)$$

Trong triển khai hiện tại, thứ tự đặc trưng được giữ cố định để quá trình huấn luyện, lưu mô hình và suy diễn luôn nhất quán.

Thành phần	Mô tả
Đặc trưng đầu vào	<code>apparent_temperature</code> , <code>humidity</code> , <code>hour_sin</code> , <code>hour_cos</code> , <code>occupancy_level</code> , <code>load_lag_24</code> .
Dữ liệu huấn luyện	Các file <code>train_1h.csv</code> , <code>train_24h.csv</code> trong <code>data/processed/scaled/core/</code> .
Dữ liệu kiểm tra	Các file <code>test_1h.csv</code> , <code>test_24h.csv</code> trong <code>data/processed/scaled/core/</code> .
Nhãn dự báo	<code>target_1h</code> cho horizon 1h và <code>target_24h</code> cho horizon 24h.
Đầu ra mô hình	Giá trị phụ tải dự báo. Trong quá trình huấn luyện, đầu ra ở miền scaled; khi đánh giá được chuyển ngược về kWh.

Bảng 4.1: Đầu vào và đầu ra của mô hình ANFIS Core

Dữ liệu **raw** vẫn được giữ để truy xuất giá trị kWh gốc và xuất file dự báo để diễn giải. Dữ liệu **scaled** được dùng trực tiếp cho ANFIS nhằm đảm bảo các đặc trưng có miền giá trị ổn định.

3. Kiến trúc mô hình

Mô hình được triển khai theo kiến trúc ANFIS 5 lớp với hàm thuộc Gaussian và hệ quả Sugeno bậc nhất. Trong thực nghiệm chính, mô hình sử dụng 6 biến đầu vào Core, 3 hàm thuộc cho mỗi biến và lưới luật đầy đủ.

Tham số	Giá trị triển khai
Số đặc trưng đầu vào	$n = 6$.
Loại hàm thuộc	Gaussian.
Số hàm thuộc mỗi đặc trưng	$m = 3$.
Số luật mờ	$N = m^n = 3^6 = 729$.
Hệ quả luật	Sugeno bậc nhất.
Hệ số Ridge	<code>ridge_alpha</code> = 1e-4.
Seed mặc định	20260527.

Bảng 4.2: Cấu hình ANFIS Core trong dự án

Với đặc trưng đầu vào x_k , độ thuộc vào tập mờ A_{ik} được tính bằng:

$$\mu_{A_{ik}}(x_k) = \exp\left(-\frac{(x_k - c_{ik})^2}{2\sigma_{ik}^2}\right) \quad (4.2)$$

Các tâm c_{ik} được khởi tạo từ phân vị của tập huấn luyện đã chuẩn hóa. Với ba hàm thuộc, mô hình dùng các mức phân vị từ 25% đến 75% để tạo các vùng đại diện cho giá trị thấp, trung bình và cao của từng đặc trưng. Tham số σ_{ik} được chọn đủ lớn để tránh hàm thuộc quá hẹp, giúp quá trình suy diễn ổn định hơn.

4. Sinh luật mờ

Do số lượng đặc trưng Core được giới hạn ở 6 biến, dự án sử dụng lưới luật đầy đủ. Mỗi luật là một tổ hợp giữa các hàm thuộc của tất cả biến đầu vào. Nếu mỗi biến có 3 tập mờ, tổng số luật là:

$$N_{\text{rules}} = 3^6 = 729 \quad (4.3)$$

Luật mờ thứ i có dạng tổng quát:

$$R_i : \text{ IF } x_1 \text{ is } A_{i1}, \dots, x_6 \text{ is } A_{i6} \text{ THEN } f_i^{(h)} = p_{i0}^{(h)} + \sum_{k=1}^6 p_{ik}^{(h)} x_k \quad (4.4)$$

Trong đó $h \in \{1h, 24h\}$ là horizon dự báo. Mỗi horizon có bộ tham số hệ quả riêng vì `target_1h` và `target_24h` mô tả hai bài toán khác nhau. Mức kích hoạt của luật được tính bằng tích các độ thuộc:

$$w_i = \prod_{k=1}^6 \mu_{A_{ik}}(x_k) \quad (4.5)$$

Sau đó các mức kích hoạt được chuẩn hóa:

$$\bar{w}_i = \frac{w_i}{\sum_{j=1}^N w_j} \quad (4.6)$$

Dự báo cuối cùng của mô hình là tổng có trọng số của các hệ quả Sugeno:

$$\hat{y}^{(h)} = \sum_{i=1}^N \bar{w}_i f_i^{(h)} \quad (4.7)$$

5. Huấn luyện mô hình

Quy trình huấn luyện được triển khai trong nhóm module mô hình của dự án. Tập tin `anfis.py` chứa phần lõi ANFIS, còn `trainer.py` điều phối huấn luyện và lưu model artifact. Phần lõi ANFIS chịu trách nhiệm tính hàm thuộc, mức kích hoạt, chuẩn hóa luật và suy diễn. Entrypoint CLI chạy thực nghiệm theo từng horizon, sau đó gọi trainer để khởi tạo mô hình, fit tham số hệ quả và ghi artifact.

Phiên bản hiện tại không tối ưu toàn bộ tham số bằng nhiều epoch lan truyền ngược. Thay vào đó, các tham số tiền đề của hàm thuộc Gaussian, gồm tâm c_{ik} và độ rộng σ_{ik} , được khởi tạo từ phân vị của tập `train_fit`. Sau khi cố định các tham số tiền đề này, mô hình fit các tham số hệ quả Sugeno bằng Ridge Least Squares thông qua phương thức `fit_consequents`.

Dữ liệu train được chia thêm thành `train_fit` và `validation`. Trong cấu hình hiện tại, `validation` bắt đầu từ mốc 2024-01-01; tập test là dữ liệu năm 2025 đã được tách từ bước tiền xử lý. Việc chia theo thời gian giúp đánh giá đúng hơn cho bài toán chuỗi thời gian.

Các bước huấn luyện cho một horizon gồm:

1. Nạp dữ liệu Core đã chuẩn hóa từ `data/processed/scaled/core/`.
2. Nạp dữ liệu raw tương ứng và các file scaler stats từ `data/processed/stats/`.
3. Tách phần train thành `train_fit` và `validation` theo mốc thời gian 2024-01-01.
4. Khởi tạo hàm thuộc Gaussian từ phân vị của `train_fit`.
5. Tạo ma trận thiết kế Sugeno từ các trọng số luật đã chuẩn hóa.
6. Fit tham số hệ quả bằng Ridge Least Squares.
7. Tính `train_rmse_scaled` trên `train_fit` và `validation_rmse_scaled` trên `validation`.
8. Lưu mô hình và metadata vào `results/{horizon}/models/`.

Cách này phù hợp với phạm vi bài tập lớn vì ổn định, dễ kiểm soát và cho phép lưu lại mô hình dưới dạng các ma trận NumPy. Ngoài pipeline chính `src/model/train_anfis_hourly.py`, dự án có script `scripts/verify_anfis_consequent_fit.py` để kiểm chứng riêng bước fit hệ quả Sugeno trên Core validation split. Script này nạp dữ liệu bằng `load_core_data`, chia dữ liệu bằng `split_train_val_test`, khởi tạo membership từ `train_fit`, fit hệ quả bằng Ridge Least Squares và lưu `model.npz` cùng `training_log.csv` trong `results/anfis_consequent_fit/`.

6. Suy diễn và chuyển ngược đơn vị

Trong giai đoạn suy diễn, mô hình nhận vector đặc trưng Core ở miền scaled và trả về dự báo scaled. Kết quả này được chuyển ngược về kWh bằng thống kê scaler của target:

$$\hat{y}_{\text{kWh}} = \hat{y}_{\text{scaled}} \times \text{range}_y + \text{min}_y \quad (4.8)$$

Trong đó min_y và range_y được lấy từ file `target_scaler_stats` tương ứng với từng horizon. Việc chuyển ngược đơn vị là cần thiết để metrics, prediction file và biểu đồ có ý nghĩa thực tế.

File dự báo trên tập test gồm các cột chính:

- `datetime`, `profile_code`, `profile_name`: thông tin thời gian và profile hộ gia đình.
- `actual_kwh`: phụ tải thực tế tại horizon cần dự báo.
- `predicted_kwh`: phụ tải do ANFIS dự báo.
- `error_kwh`, `abs_error_kwh`, `ape`: các sai số phục vụ đánh giá.

7. Đánh giá và lưu artifact

Sau khi huấn luyện, mỗi horizon được đánh giá trên tập test bằng các metrics hồi quy như MAE, RMSE, MAPE và R^2 . Các kết quả này được tính trên miền kWh sau khi chuyển ngược đơn vị, nhờ đó có thể diễn giải trực tiếp theo sai số phụ tải thực tế. Các mô hình baseline học máy được trình bày riêng trong Chương 5 để phục vụ so sánh thực nghiệm.

Toàn bộ kết quả được lưu riêng theo horizon. Mỗi thư mục kết quả theo horizon có các nhóm artifact sau:

Thư mục	Nội dung
<code>models/</code>	File mô hình ANFIS dạng <code>.npz</code> .
<code>metrics/</code>	Metrics JSON/CSV, training log và cấu hình chạy.
<code>predictions/</code>	File CSV chứa giá trị thực tế, dự báo và sai số.
<code>plots/</code>	Biểu đồ Actual vs Predicted, phân phối residual và membership functions.

Bảng 4.3: Cấu trúc artifact sau huấn luyện

Cách tổ chức artifact này giúp mỗi lần chạy có thể truy vết lại dữ liệu, tham số mô hình, metrics và biểu đồ tương ứng. Khi cần so sánh nhiều thí nghiệm, chỉ cần đối chiếu các file `config.json`, `metrics.json` và `training_log.csv` theo `run_id`.

Algorithm 1 Quy trình dự báo phụ tải điện bằng ANFIS cho hai horizon.

Input: dữ liệu thời tiết theo giờ, profile hộ gia đình, dữ liệu phụ tải mô phỏng, Core Features, target_1h, target_24h.

Output: mô hình ANFIS, metrics, predictions và plots cho results/1h/ và results/24h/.

```
horizons = [1h, 24h]
core_features = [apparent_temperature, humidity, hour_sin,
                 hour_cos, occupancy_level, load_lag_24]

-- Data preparation and feature engineering --
# collect weather, build profiles and create hourly load series
weather = load_hourly_weather(Hanoi, 2021-2025)
profiles = build_household_profiles()
data = simulate_hourly_load(weather, profiles)
data = inject_anomaly_and_spike(data)
data = check_missing_values_and_duplicate_rows(data)
# create lag features, rolling features and forecast targets
data = create_lag_and_rolling_features(data)
data[target_1h] = shift(load_kwh, -1)
data[target_24h] = shift(load_kwh, -24)

-- Preprocessing per horizon --
for horizon in horizons:
    # fit scalers on train only to avoid leakage
    target = target_columns[horizon]
    train, test = split_by_time(data, train_end=2025-01-01)
    feature_scaler = fit_minmax_scaler(train[core_features])
    target_scaler = fit_minmax_scaler(train[target])
    save_raw_and_scaled_core_extended(train, test, horizon)

-- ANFIS training --
for horizon in horizons:
    # train one ANFIS model for each forecast horizon
    core_data = load_core_data(horizon)
    train_fit, validation, test = split_train_val_test(core_data)
    X_train, y_train = get_scaled_core(train_fit)
    X_val, y_val = get_scaled_core(validation)
    X_test, y_test = get_scaled_core(test)
    model = ANFIS(n_mfs=3, mf=Gaussian, rules=3^6)
    model.initialize_memberships(X_train)
    model.fit_consequents(X_train, y_train, Ridge)
    train_rmse_scaled = rmse(model.predict(X_train), y_train)
    validation_rmse_scaled = rmse(model.predict(X_val), y_val)

-- Evaluation and artifact export --
# convert predictions to kWh and save reproducible artifacts
pred_scaled = model.predict(X_test)
pred_kwh = inverse_target_scaler(pred_scaled, horizon)
metrics = evaluate(actual_kwh, pred_kwh)
save(model, metrics, predictions, plots, horizon)
return results/1h and results/24h artifacts
```

Bảng 4.4: Pseudocode quy trình triển khai đề tài

CHƯƠNG 5. THỰC NGHIỆM VÀ ĐÁNH GIÁ MÔ HÌNH

1. Môi trường thực nghiệm

Các thực nghiệm được thực hiện trên cùng một môi trường cục bộ của dự án nhằm đảm bảo dữ liệu, cấu hình huấn luyện và kết quả đánh giá có thể truy vết lại được. Chương này sử dụng trực tiếp các artifact đã được lưu trong thư mục **results/**, bao gồm metrics, file dự báo và các biểu đồ đánh giá.

Bảng 5.1: Môi trường phần mềm sử dụng trong thực nghiệm

Thành phần	Giá trị
Ngôn ngữ lập trình	Python 3.10.0.
Thư viện xử lý dữ liệu	pandas 2.3.3, numpy 2.2.6.
Thư viện học máy	scikit-learn 1.6.1, xgboost 3.2.0.
Thư viện trực quan hóa	matplotlib 3.10.8.
Dữ liệu xử lý	data/processed/raw/, data/processed/scaled/ và data/processed/stats/.
Thư mục kết quả chính	results/1h/, results/24h/ và results/baselines/.
Thư mục kiểm chứng ANFIS	results/anfis_consequent_fit/.

Thông tin phần cứng không được lưu trong artifact của lần chạy, do đó báo cáo không sử dụng cấu hình CPU, RAM hoặc GPU để giải thích sự khác biệt kết quả. Trọng tâm đánh giá là chất lượng dự báo trên cùng tập kiểm tra và cùng hệ thống độ đo.

2. Thiết lập thực nghiệm

Thực nghiệm được thiết kế cho hai mốc dự báo: 1h và 24h. Mốc 1h đánh giá khả năng dự báo phụ tải ở giờ kế tiếp, còn mốc 24h đánh giá khả năng dự báo phụ tải cùng giờ của ngày tiếp theo. Cả hai mốc đều sử dụng tập kiểm tra năm 2025, tức dữ liệu không tham gia vào quá trình học tham số mô hình.

Đối với mô hình ANFIS, báo cáo sử dụng run mới nhất trong thư mục kết quả, gồm 1h_20260606_001123 và 24h_20260606_001123. Hai run này sử dụng Core Dataset với sáu đặc trưng `apparent_temperature`, `humidity`, `hour_sin`, `hour_cos`, `occupancy_level` và `load_lag_24`. Các mô hình baseline học máy sử dụng Extended Dataset để khai thác nhiều đặc trưng hơn cho mục tiêu so sánh thực nghiệm.

Bảng 5.2: Thiết lập dữ liệu cho thực nghiệm ANFIS

Horizon	Train-fit	Validation	Test	Target
1h	105 024	35 136	34 944	target_1h
24h	105 024	35 136	34 944	target_24h

Cấu hình ANFIS của hai run giống nhau: số hàm thuộc Gaussian trên mỗi đặc trưng là `n_mfs = 3`, hệ số Ridge là `ridge_alpha = 0.0001`, seed là 20260527. Với 6 đặc trưng Core, số luật mờ được sinh ra là $3^6 = 729$. Kết quả ANFIS được lấy từ `results/1h/metrics/` và `results/24h/metrics/`; kết quả baseline được tổng hợp trong `results/baselines/metrics/baseline_metrics_all.csv`.

Các độ đo sử dụng gồm MAE, RMSE, MAPE và R^2 . MAE và RMSE có đơn vị kWh, MAPE được tính theo phần trăm, còn R^2 phản ánh mức độ giải thích phương sai của mô hình. Với MAE, RMSE và MAPE, giá trị càng nhỏ càng tốt; với R^2 , giá trị càng lớn càng tốt.

Bảng cấu hình ANFIS ở trên mô tả run chính dùng để đánh giá trên tập test, với `n_mfs = 3` và $3^6 = 729$ luật mờ. Bên cạnh đó, đề tài có thêm script `scripts/verify_anfis_consequent_fit.py` để kiểm chứng riêng bước fit hệ quả Sugeno trên Core validation split. Script này dùng cấu hình nhỏ hơn, gồm `n_mfs = 2` và $2^6 = 64$ luật, nhằm kiểm tra tính đúng đắn của phương thức `fit_consequents` bằng Ridge Least Squares; đây không phải là cấu hình dùng cho kết quả thực nghiệm cuối cùng trên tập test. Kết quả kiểm chứng được lưu riêng theo horizon tại `results/anfis_consequent_fit/1h/training_log.csv` và `results/anfis_consequent_fit/24h/training_log.csv`.

Bảng 5.3: Kết quả kiểm chứng nội bộ bước fit hệ quả Sugeno

Horizon	Target	n_mfs	Luật	Train-fit	Validation	Train RMSE	Val. RMSE
1h	target_1h	2	64	105 024	35 136	0.0355105619	0.0365460145
24h	target_24h	2	64	105 024	35 136	0.0410750799	0.0442226909

Bảng 5.3 cho thấy sai số trên validation chỉ cao hơn nhẹ so với train-fit trong miền scaled. Điều này xác nhận bước fit hệ quả Sugeno bằng Ridge Least Squares hoạt động đúng với dữ liệu Core và không tạo dự báo NaN/Inf. Kết quả này là kiểm chứng nội bộ của bước huấn luyện, còn chất lượng dự báo cuối cùng vẫn được đánh giá trên tập test năm 2025 ở các mục tiếp theo.

3. Các mô hình so sánh

Chương 4 đã trình bày chi tiết thiết kế và triển khai ANFIS, vì vậy phần này chỉ mô tả vai trò của các mô hình trong thực nghiệm. ANFIS là mô hình chính của đề tài và chỉ sử dụng Core Dataset. Các mô hình `Linear Regression`, `Decision`

Tree, Random Forest và XGBoost được huấn luyện trên Extended Dataset để làm baseline so sánh.

Bảng 5.4: Các mô hình sử dụng trong thực nghiệm

Mô hình	Dữ liệu	Vai trò trong thực nghiệm
ANFIS	core	Mô hình chính của đề tài, sử dụng 6 đặc trưng Core, hàm thuộc Gaussian và hệ quả Sugeno bậc nhất.
Linear Regression	extended	Baseline tuyến tính, dùng để kiểm tra mức độ tuyến tính của quan hệ giữa đặc trưng và phụ tải.
Decision Tree	extended	Mô hình cây đơn với <code>max_depth = 10</code> , dùng để đánh giá khả năng học quan hệ phi tuyến đơn giản.
Random Forest	extended	Mô hình ensemble gồm 100 cây, dùng để so sánh với một baseline phi tuyến ổn định hơn cây đơn.
XGBoost	extended	Mô hình boosting với <code>n_estimators = 200</code> , <code>learning_rate = 0.05</code> và <code>max_depth = 5</code> .

Việc so sánh giữa ANFIS Core và các baseline Extended cho phép đánh giá hai khía cạnh. Thứ nhất, ANFIS có đạt hiệu quả tốt khi chỉ dùng tập đặc trưng rút gọn hay không. Thứ hai, các mô hình học máy phổ biến có tận dụng tốt hơn thông tin bổ sung trong Extended Dataset hay không.

4. Kết quả thực nghiệm cho dự báo 1 giờ tới


Bảng 5.5 trình bày kết quả đánh giá trên tập kiểm tra năm 2025 cho mốc dự báo 1h. Các giá trị của ANFIS được lấy từ file `1h_20260606_001123_metrics.csv`; kết quả baseline được lấy từ các dòng `extended` trong `baseline_metrics_all.csv`.

Bảng 5.5: Kết quả dự báo 1 giờ tới trên tập test

Model	MAE	RMSE	MAPE	R^2
Linear Regression	0.205	0.302	33.43	0.736
Decision Tree	0.106	0.180	17.26	0.905
Random Forest	0.084	0.154	13.90	0.931
XGBoost	0.087	0.154	14.57	0.931
ANFIS	0.113	0.191	18.41	0.895


Ở mốc dự báo 1 giờ tới, ANFIS đạt MAE 0.113 kWh, RMSE 0.191 kWh và R^2 đạt 0.895. Kết quả này tốt hơn đáng kể so với Linear Regression, cho thấy quan hệ giữa các đặc trưng và phụ tải điện không thuần tuyến tính. Tuy nhiên, các mô hình ensemble trên Extended Dataset đạt sai số thấp hơn, trong đó Random Forest cho MAE và RMSE tốt nhất.

Kết quả này phản ánh sự đánh đổi giữa khả năng diễn giải và khả năng khai thác đặc trưng. ANFIS chỉ dùng 6 Core Features để kiểm soát số luật mờ, trong khi các baseline Extended có thêm nhiều biến mô tả thời tiết, hành vi và phụ tải lịch sử.



Hình 5.1: Dự báo ANFIS so với giá trị thực tế cho horizon 1h

Hình 5.1 cho thấy đường dự báo của ANFIS nhìn chung bám sát xu hướng thực tế trong giai đoạn minh họa. Tuy nhiên, tại một số điểm có biến động đột ngột hoặc spike, mô hình có xu hướng làm mượt biên độ dự báo, dẫn đến sai số lớn hơn ở các đỉnh phụ tải.



Hình 5.2: Phân phối residual của ANFIS cho horizon 1h

5. Kết quả thực nghiệm cho dự báo 24 giờ tới


Bảng 5.6 trình bày kết quả đánh giá cho mốc dự báo 24h. Các giá trị ANFIS được lấy từ file 24h_20260606_001123_metrics.csv; kết quả baseline được lấy từ các dòng extended trong baseline_metrics_all.csv.

Bảng 5.6: Kết quả dự báo 24 giờ tới trên tập test

Model	MAE	RMSE	MAPE	R^2
Linear Regression	0.172	0.251	27.50	0.818
Decision Tree	0.149	0.231	24.11	0.845
Random Forest	0.134	0.214	21.50	0.868
XGBoost	0.133	0.211	21.42	0.871
ANFIS	0.148	0.235	23.83	0.840

Ở horizon 24h, sai số của ANFIS tăng so với horizon 1h: RMSE tăng từ 0.191 kWh lên 0.235 kWh và R^2 giảm từ 0.895 xuống 0.840. Xu hướng này phù hợp với bản chất khó hơn của bài toán dự báo xa hơn, khi mô hình phải dự đoán phụ tải của ngày kế tiếp thay vì giờ kế tiếp.


Trong nhóm mô hình so sánh, XGBoost trên Extended Dataset cho kết quả tốt nhất với RMSE 0.211 kWh và R^2 đạt 0.871. Random Forest cũng cho kết quả gần tương đương. Điều này cho thấy các mô hình ensemble có khả năng khai thác tốt hơn nhóm đặc trưng mở rộng, đặc biệt khi dữ liệu có nhiều quan hệ phi tuyến và tương tác giữa thời tiết, chu kỳ thời gian và hành vi sử dụng điện.



Hình 5.3: Dự báo ANFIS so với giá trị thực tế cho horizon 24h

Hình 5.3 cho thấy ANFIS vẫn nắm bắt được cấu trúc dao động theo chu kỳ ngày. Tuy nhiên, với mốc dự báo 24 giờ, các sai lệch tại vùng cao điểm xuất hiện rõ hơn so với horizon 1h, đặc biệt tại các đoạn có spike hoặc thay đổi bất thường

trong phụ tải thực tế.




Hình 5.4: Phân phối residual của ANFIS cho horizon 24h

6. So sánh và thảo luận kết quả

Kết quả tổng thể cho thấy mốc dự báo 1h dễ hơn mốc 24h. Với ANFIS, RMSE tăng từ 0.191 kWh ở horizon 1h lên 0.235 kWh ở horizon 24h; R^2 giảm từ 0.895 xuống 0.840. Xu hướng tương tự cũng xuất hiện ở hầu hết baseline, cho thấy độ bất định tăng khi khoảng cách dự báo xa hơn.

Khi so sánh giữa các nhóm mô hình, **Linear Regression** là mô hình yếu nhất trong cả hai horizon. Điều này cho thấy quan hệ giữa các đặc trưng và phụ tải điện không thuần tuyến tính. **Decision Tree** cải thiện đáng kể so với **Linear Regression**, nhưng kết quả chưa ổn định bằng **Random Forest** và **XGBoost**. Hai mô hình ensemble đạt kết quả tốt nhất nhờ khả năng kết hợp nhiều cây quyết định và khai thác quan hệ phi tuyến trong dữ liệu.

ANFIS đạt kết quả tốt với tập Core Features và duy trì khả năng diễn giải thông qua hàm thuộc và luật mờ. Tuy nhiên, khi so sánh với **Random Forest** và **XGBoost** trên Extended Dataset, ANFIS chưa phải mô hình có sai số thấp nhất. Nguyên nhân chính là ANFIS trong dự án chỉ sử dụng tập core gồm 6 đặc trưng để tránh bùng nổ số luật mờ, trong khi các baseline có thể khai thác tập extended với số đặc trưng lớn hơn.



Hình 5.5: So sánh RMSE giữa các mô hình baseline trên tập kiểm tra

Hình 5.5 cho thấy trong nhóm baseline trên tập **extended**, các mô hình cây ensemble có RMSE thấp hơn rõ rệt so với **Linear Regression**. Kết quả này củng cố nhận định rằng dữ liệu phụ tải điện theo giờ có cấu trúc phi tuyến và chịu tác động đồng thời của nhiều nhóm đặc trưng.

7. Nhận xét chung

Từ các thực nghiệm đã thực hiện, có thể rút ra một số nhận xét chính. Thứ nhất, ANFIS đạt chất lượng dự báo tốt khi chỉ sử dụng Core Dataset, chứng minh rằng nhóm đặc trưng rút gọn vẫn chứa thông tin quan trọng cho bài toán phụ tải điện theo giờ. Thứ hai, ANFIS vượt **Linear Regression**, cho thấy bài toán có tính phi tuyến rõ rệt.

Thứ ba, các mô hình ensemble như **Random Forest** và **XGBoost** đạt sai số thấp nhất khi được huấn luyện trên Extended Dataset. Điều này cho thấy tập đặc trưng mở rộng chứa thêm thông tin hữu ích cho dự báo. Tuy nhiên, việc đưa toàn bộ đặc trưng mở rộng vào ANFIS cần được cân nhắc vì số luật mờ sẽ tăng rất nhanh theo số biến đầu vào.

Nhìn chung, ANFIS là lựa chọn phù hợp khi cần cân bằng giữa khả năng dự báo và khả năng diễn giải bằng luật mờ. Nếu mục tiêu chính là tối ưu sai số dự báo, các mô hình ensemble trên tập đặc trưng mở rộng đang cho kết quả tốt hơn trong thực nghiệm hiện tại. Đây là cơ sở để định hướng các bước cải tiến tiếp theo, chẳng hạn chọn lọc đặc trưng quan trọng trước khi đưa vào ANFIS hoặc thử các chiến lược sinh luật mờ không dùng lưới đầy đủ.

TỔNG KẾT

Đề tài đã xây dựng khung nghiên cứu và triển khai hệ Neuro-Fuzzy thích nghi ANFIS cho bài toán dự báo phụ tải điện hộ gia đình theo giờ. Bài toán được thiết kế cho hai mốc dự báo gồm 1 giờ tới và 24 giờ tới, tương ứng với hai nhãn `target_1h` và `target_24h`. Dữ liệu đầu vào được xây dựng từ dữ liệu thời tiết theo giờ tại Hà Nội, các hồ sơ sinh hoạt hộ gia đình và chuỗi phụ tải điện mô phỏng.

Về mặt mô hình, ANFIS dạng Sugeno được lựa chọn do phù hợp với bài toán hồi quy và có khả năng giải thích thông qua luật mờ. Mô hình ANFIS sử dụng Core Features gồm `apparent_temperature`, `humidity`, `hour_sin`, `hour_cos`, `occupancy_level` và `load_lag_24`. Dữ liệu được chia train/test theo thời gian, trong đó train là giai đoạn trước năm 2025 và test là dữ liệu năm 2025; scaler được fit trên tập train rồi áp dụng cho cả train và test.

Kết quả thực nghiệm cho thấy ANFIS cải thiện rõ rệt so với **Linear Regression**, xác nhận lợi thế của mô hình phi tuyến trong bài toán phụ tải điện theo giờ. Khi so sánh với các mô hình học máy sử dụng Extended Dataset, các mô hình ensemble như **Random Forest** và **XGBoost** đạt sai số thấp hơn trong thực nghiệm hiện tại. Điều này cho thấy ANFIS có ưu điểm về khả năng diễn giải, trong khi các mô hình baseline có lợi thế khi khai thác nhiều đặc trưng mở rộng.

Trong giai đoạn tiếp theo, hệ thống có thể được cải tiến bằng cách chọn lọc đặc trưng quan trọng trước khi đưa vào ANFIS, thử các phương pháp sinh luật mờ không dùng lưới đầy đủ và đánh giá trên dữ liệu công tơ điện thực tế. Ngoài ra, việc cá nhân hóa mô hình theo lịch sử sử dụng điện của từng hộ gia đình cũng là một hướng mở rộng có ý nghĩa thực tiễn.

Nhận xét và định hướng hoàn thiện - lần nộp 1 (6/6)

Mặc dù nhóm em đã xây dựng được quy trình tiền xử lý dữ liệu, huấn luyện và đánh giá mô hình dự báo phụ tải điện, tuy nhiên chúng em nhận thấy nghiên cứu hiện tại vẫn còn một số hạn chế. Dữ liệu phụ tải điện được xây dựng theo phương pháp mô phỏng dựa trên hồ sơ sinh hoạt hộ gia đình thay vì thu thập từ công tơ điện thực tế, do đó chưa thể phản ánh đầy đủ các đặc điểm tiêu thụ điện trong môi trường vận hành thực tế. Bên cạnh đó, kết quả thực nghiệm cho thấy ANFIS có ưu thế về khả năng diễn giải thông qua các luật mờ, tuy nhiên hiệu năng dự báo vẫn còn khoảng cách so với một số mô hình ensemble như **Random Forest** và **XGBoost** khi sử dụng tập đặc trưng mở rộng.

Vậy nên nhóm chúng em xem đây là giai đoạn đầu nhằm kiểm chứng tính khả thi của hướng tiếp cận Neuro-Fuzzy đối với bài toán dự báo phụ tải điện. Trong

lần hoàn thiện tiếp theo (lần nộp 2 trước ngày thi), chúng em sẽ cố gắng điều chỉnh kiến trúc mô hình, lựa chọn tập đặc trưng phù hợp hơn và từng bước tiếp cận các nguồn dữ liệu thực tế để nâng cao giá trị ứng dụng của đề tài.

Nhóm chúng em rất mong nhận được lời nhận xét, đánh giá và góp ý từ thầy về tính phù hợp của hướng nghiên cứu hiện tại, cũng như những định hướng chuyên môn cần ưu tiên trong giai đoạn tiếp theo để đề tài có thể phát triển theo hướng thực tiễn và có giá trị ứng dụng cao hơn ạ.

Em Long và em Nguyên xin chân thành cảm ơn thầy đã dành thời gian xem xét và góp ý cho đề tài của nhóm ạ!

Kính chúc thầy luôn có thật nhiều sức khỏe ạ <33

TÀI LIỆU THAM KHẢO

- [1] L. A. Zadeh, “Fuzzy Sets,” *Information and Control*, vol. 8, no. 3, pp. 338–353, 1965, doi: [https://doi.org/10.1016/S0019-9958\(65\)90241-X](https://doi.org/10.1016/S0019-9958(65)90241-X).
- [2] T. Takagi and M. Sugeno, “Fuzzy Identification of Systems and Its Applications to Modeling and Control,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. SMC-15, no. 1, pp. 116–132, 1985, doi: <https://doi.org/10.1109/TSMC.1985.6313399>.
- [3] J.-S. R. Jang, “ANFIS: Adaptive-Network-Based Fuzzy Inference System,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 23, no. 3, pp. 665–685, 1993, doi: <https://doi.org/10.1109/21.256541>.
- [4] S. Haykin, *Neural Networks and Learning Machines*, 3rd ed. Upper Saddle River, NJ, USA: Pearson, 2009.
- [5] T. Hong and S. Fan, “Probabilistic Electric Load Forecasting: A Tutorial Review,” *International Journal of Forecasting*, vol. 32, no. 3, pp. 914–938, 2016, doi: <https://doi.org/10.1016/j.ijforecast.2015.11.011>.
- [6] R. J. Hyndman and A. B. Koehler, “Another Look at Measures of Forecast Accuracy,” *International Journal of Forecasting*, vol. 22, no. 4, pp. 679–688, 2006, doi: <https://doi.org/10.1016/j.ijforecast.2006.03.001>.
- [7] Open-Meteo, “Historical Weather API,” Open-Meteo.com. [Online]. Available: <https://open-meteo.com/en/docs/historical-weather-api>. Accessed: Jun. 6, 2026.
- [8] Tập đoàn Điện lực Việt Nam, “Trang thông tin điện tử tổng hợp EVN.” [Online]. Available: <https://www.evn.com.vn/>. Accessed: Jun. 6, 2026.
- [9] F. Pedregosa *et al.*, “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [10] C. R. Harris *et al.*, “Array Programming with NumPy,” *Nature*, vol. 585, pp. 357–362, 2020, doi: <https://doi.org/10.1038/s41586-020-2649-2>.
- [11] W. McKinney, “Data Structures for Statistical Computing in Python,” in *Proceedings of the 9th Python in Science Conference*, Austin, TX, USA, 2010, pp. 56–61.

- [12] J. D. Hunter, “Matplotlib: A 2D Graphics Environment,” *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007, doi: <https://doi.org/10.1109/MCSE.2007.55>.

DANH MỤC THUẬT NGỮ VÀ VIẾT TẮT

Mô hình và phương pháp

Thuật ngữ / viết tắt	Ý nghĩa trong đề tài
ANFIS	Adaptive Neuro-Fuzzy Inference System – hệ suy diễn Neuro-Fuzzy thích nghi dùng để dự báo phụ tải điện.
Neuro-Fuzzy	Hướng tiếp cận kết hợp mạng nơ-ron với logic mờ để vừa học từ dữ liệu vừa giữ khả năng diễn giải.
Mạng nơ-ron	Neural network – mô hình học ánh xạ phi tuyến giữa đặc trưng đầu vào và phụ tải đầu ra.
Sugeno	Dạng hệ suy diễn mờ có hệ quả là hàm tuyến tính hoặc hằng số, phù hợp với bài toán hồi quy.
Gaussian	Hàm thuộc dạng chuông được dùng để mờ hóa đặc trưng đầu vào trong ANFIS.
Vector	Tập hợp đặc trưng đầu vào tại một thời điểm, ký hiệu thường dùng là $\mathbf{x}_t$.

Đặc trưng dữ liệu và nhãn dự báo

Thuật ngữ / viết tắt	Ý nghĩa trong đề tài
apparent_temperature	Nhiệt độ cảm nhận, phản ánh tác động tổng hợp của thời tiết tới nhu cầu sử dụng điện.
humidity	Độ ẩm không khí theo giờ, dùng làm đặc trưng thời tiết.
hour_sin	Thành phần sin của mã hóa chu kỳ giờ trong ngày.
hour_cos	Thành phần cos của mã hóa chu kỳ giờ trong ngày.
occupancy_level	Mức hiện diện hoặc mức hoạt động của hộ gia đình tại thời điểm quan sát.
load_lag_24	Phụ tải tại thời điểm cách hiện tại 24 giờ, dùng để nắm chu kỳ theo ngày.
Lag features	Nhóm đặc trưng trễ được tạo từ phụ tải trong quá khứ, ví dụ load_lag_1 và load_lag_24.
Rolling features	Nhóm đặc trưng thống kê trượt theo cửa sổ thời gian, ví dụ trung bình phụ tải 3 giờ hoặc 24 giờ.
target_1h	Nhãn đầu ra cho bài toán dự báo phụ tải 1 giờ tới.
target_24h	Nhãn đầu ra cho bài toán dự báo phụ tải 24 giờ tới.
Profile	Hồ sơ hộ gia đình mô phỏng, mô tả quy mô và thói quen sử dụng điện.
EVN	Tập đoàn Điện lực Việt Nam; trong báo cáo được nhắc như nguồn dữ liệu thực tế tiềm năng ở hướng phát triển.

Tiền xử lý và cấu trúc dữ liệu

Thuật ngữ / viết tắt	Ý nghĩa trong đề tài
Train/Test	Cách chia dữ liệu thành tập huấn luyện và tập kiểm tra theo trục thời gian.
Min-Max Scaling	Phương pháp chuẩn hóa dữ liệu về miền giá trị cố định dựa trên giá trị nhỏ nhất và lớn nhất của tập huấn luyện.
Fit scaler	Bước học tham số scaler trên tập train trước khi áp dụng cho train/test.
Raw	Dữ liệu chưa chuẩn hóa, giữ đơn vị và miền giá trị gốc.
Scaled	Dữ liệu đã chuẩn hóa để đưa vào mô hình.
Core	Nhóm đặc trưng cốt lõi dùng trực tiếp cho ANFIS.
Extended	Nhóm đặc trưng mở rộng dùng cho mô hình so sánh hoặc thí nghiệm bổ sung.
Missing values	Các giá trị bị thiếu trong dữ liệu cần được kiểm tra và xử lý trước khi huấn luyện.
Duplicate rows	Các dòng dữ liệu trùng lặp cần được phát hiện để tránh làm sai lệch tập huấn luyện.

Quy trình và phạm vi dự báo

Thuật ngữ / viết tắt	Ý nghĩa trong đề tài
Workflow	Luồng xử lý tổng thể từ thu thập dữ liệu, sinh phụ tải, tiền xử lý, huấn luyện đến đánh giá.
Horizon	Mốc thời gian dự báo trong tương lai, gồm 1h và 24h.
Anomaly/spike	Điểm bất thường hoặc tăng đột biến trong chuỗi phụ tải được mô phỏng để gần với hành vi thực tế.

Artifact và kết quả đầu ra

Thuật ngữ / viết tắt	Ý nghĩa trong đề tài
Artifact	File hoặc sản phẩm đầu ra của pipeline, ví dụ model, metrics, biểu đồ và prediction.
Metrics	Các chỉ số đánh giá mô hình như MAE, RMSE, MAPE và R^2 .
Plots	Nhóm biểu đồ trực quan hóa kết quả dự báo và sai số.
Models	Nhóm file lưu tham số hoặc cấu hình mô hình sau huấn luyện.
Predictions	Nhóm file lưu giá trị dự báo và giá trị thực tế trên tập kiểm tra.
File	Đơn vị lưu trữ artifact, thường ở định dạng CSV, JSON, NPZ hoặc PNG.