

TRƯỜNG ĐẠI HỌC THỦY LỢI

KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO BÀI TẬP LỚN HỌC PHẦN TÍNH TOÁN MỀM

ĐỀ TÀI: Xây dựng hệ Neuro-Fuzzy thích nghi (ANFIS) dự báo điện năng tiêu thụ hộ gia đình dựa trên thông tin người dùng, thiết bị, thời gian, vị trí và yếu tố khí tượng.

Giảng viên phụ trách môn học: Th.S Trần Mạnh Tuấn

Nhóm thực hiện: Nhóm 2

Thành viên nhóm:

Nguyễn Ngọc Long	Mã sinh viên
Nguyễn Phúc Nguyên	Mã sinh viên

Hà Nội, tháng 5 năm 2026

Mục lục

LỜI NÓI ĐẦU	1
MÔ TẢ ĐỀ TÀI	2
1. Tên đề tài	2
2. Mục tiêu tổng quát	2
3. Đầu vào và đầu ra của hệ thống	2
4. Phạm vi thực hiện	2
5. Kết quả mong đợi	3
CHƯƠNG 1. Giới thiệu bài toán	4
1. Đặt vấn đề	4
2. Mục tiêu của đề tài	4
3. Đối tượng và phạm vi nghiên cứu	5
4. Phương pháp thực hiện (Workflow)	5
5. Cấu trúc dữ liệu và kết quả	7
6. Bố cục báo cáo	7
CHƯƠNG 2. Cơ sở lý thuyết	8
1. Bài toán dự báo phụ tải điện theo chuỗi thời gian	8
2. Đặc trưng đầu vào	8
3. Tiền xử lý dữ liệu	9
4. Logic mờ	9
5. Mạng nơ-ron và mô hình Neuro-Fuzzy	10
6. Hệ suy diễn Neuro-Fuzzy thích nghi ANFIS	10
6.1. Năm lớp của ANFIS	10
7. Các độ đo đánh giá	11
7.1. MAE	12
7.2. RMSE	12
7.3. MAPE và MPE	12
7.4. Hệ số xác định R^2	12
CHƯƠNG 3. Dữ liệu và tiền xử lý dữ liệu	13

1. Nguồn dữ liệu	13
CHƯƠNG 4. Thiết kế và triển khai mô hình ANFIS	14
1. Mục tiêu triển khai	14
2. Đầu vào, đầu ra và phạm vi mô hình	14
3. Kiến trúc mô hình	15
4. Sinh luật mờ	15
5. Huấn luyện mô hình	16
6. Suy diễn và chuyển ngược đơn vị	17
7. Đánh giá và lưu artifact	17
CHƯƠNG 5. Thực nghiệm và đánh giá mô hình	20
TỔNG KẾT	21
TÀI LIỆU THAM KHẢO	21
DANH MỤC THUẬT NGỮ VÀ VIẾT TẮT	24

LỜI NÓI ĐẦU

Trong bối cảnh nhu cầu sử dụng điện sinh hoạt ngày càng biến động theo thời tiết, lịch sinh hoạt và thói quen sử dụng thiết bị, dự báo phụ tải điện ngắn hạn có ý nghĩa quan trọng đối với quản lý năng lượng hộ gia đình. Một dự báo sát thực tế giúp người dùng chủ động điều chỉnh hành vi tiêu thụ điện, đồng thời hỗ trợ các hệ thống quản lý điện xây dựng kế hoạch vận hành ổn định hơn.

Đề tài “Xây dựng hệ Neuro-Fuzzy thích nghi (ANFIS) dự báo phụ tải điện hộ gia đình cho hai mốc 1 giờ và 24 giờ tới” được thực hiện nhằm nghiên cứu khả năng kết hợp giữa logic mờ và mạng nơ-ron trong bài toán dự báo chuỗi thời gian. Hai mốc dự báo được lựa chọn vì có ý nghĩa sử dụng khác nhau: dự báo 1 giờ tới phục vụ phản ứng nhanh trong ngày, còn dự báo 24 giờ tới hỗ trợ lập kế hoạch tiêu thụ điện cho ngày kế tiếp.

Trong báo cáo này, nhóm trình bày cơ sở lý thuyết của ANFIS, quy trình xây dựng dữ liệu phụ tải điện theo giờ, thiết kế đặc trưng thời gian – thời tiết – hành vi, tiền xử lý dữ liệu, huấn luyện mô hình và đánh giá kết quả cho hai horizon 1h và 24h. Dữ liệu được tổ chức theo cấu trúc rõ ràng gồm nhóm Core Features dành cho ANFIS và Extended Features dành cho các mô hình so sánh hoặc thí nghiệm mở rộng.

Do dữ liệu thực tế từ công tơ hộ gia đình còn khó thu thập đầy đủ, đề tài sử dụng dữ liệu thời tiết thực tế tại Hà Nội kết hợp với dữ liệu phụ tải được mô phỏng theo các hồ sơ sinh hoạt. Đây là một hướng tiếp cận phù hợp trong phạm vi bài tập lớn, giúp nhóm xây dựng được quy trình hoàn chỉnh từ thu thập dữ liệu, sinh đặc trưng, huấn luyện, đánh giá đến lưu trữ kết quả theo từng mốc dự báo.

Nhóm thực hiện xin chân thành cảm ơn giảng viên phụ trách học phần đã hướng dẫn và góp ý trong quá trình thực hiện đề tài.

Nhóm thực hiện

MÔ TẢ ĐỀ TÀI

1. Tên đề tài

Xây dựng hệ Neuro-Fuzzy thích nghi (ANFIS) dự báo phụ tải điện hộ gia đình cho hai mốc 1 giờ và 24 giờ tới.

2. Mục tiêu tổng quát

Đề tài hướng tới xây dựng một mô hình dự báo phụ tải điện sinh hoạt theo giờ bằng mô hình ANFIS. Với một thời điểm quan sát t , hệ thống dự báo điện năng tiêu thụ của hộ gia đình tại hai mốc tương lai:

- **Dự báo 1 giờ tới:** ước lượng phụ tải tại thời điểm $t + 1$.
- **Dự báo 24 giờ tới:** ước lượng phụ tải tại thời điểm $t + 24$.

Hai đầu ra này giúp đánh giá mô hình ở cả tình huống dự báo rất ngắn hạn và tình huống lập kế hoạch cho ngày kế tiếp. Mô hình sử dụng các đặc trưng về thời tiết, chu kỳ thời gian, mức hiện diện của hộ gia đình và phụ tải trong quá khứ để suy diễn kết quả dự báo.

3. Đầu vào và đầu ra của hệ thống

Nhóm thông tin	Mô tả
Dữ liệu nguồn	Dữ liệu thời tiết theo giờ tại Hà Nội và dữ liệu phụ tải điện hộ gia đình được mô phỏng theo các hồ sơ sinh hoạt.
Đặc trưng Core	<code>apparent_temperature</code> , <code>humidity</code> , <code>hour_sin</code> , <code>hour_cos</code> , <code>occupancy_level</code> , <code>load_lag_24</code> . Đây là nhóm đặc trưng chính dùng cho ANFIS.
Đặc trưng Extended	Các đặc trưng mở rộng về hộ gia đình, thời tiết, chu kỳ ngày/tháng, ngày nghỉ, hành vi sử dụng điện, lag features và rolling features.
Đầu ra	<code>target_1h</code> cho dự báo 1 giờ tới và <code>target_24h</code> cho dự báo 24 giờ tới, đơn vị kWh.
Artifact kết quả	Mô hình, metrics, biểu đồ và file dự báo được lưu riêng trong <code>results/1h/</code> và <code>results/24h/</code> .

Bảng 0.1: Mô tả đầu vào và đầu ra dự kiến của hệ thống

4. Phạm vi thực hiện

Trong phạm vi bài tập lớn, hệ thống tập trung vào dự báo phụ tải điện sinh hoạt theo giờ tại Hà Nội. Dữ liệu thời tiết được lấy theo giờ trong giai đoạn 2021–2025,

sau đó kết hợp với các profile hộ gia đình để mô phỏng chuỗi phụ tải điện. Dữ liệu được chia train/test theo thời gian, chuẩn hóa bằng Min-Max Scaling trên tập train và lưu thành hai nhóm **raw** và **scaled**.

Đề tài chưa sử dụng dữ liệu công tơ điện thực tế từ EVN và chưa xét các yếu tố bất thường ngoài mô phỏng như mất điện diện rộng, thay đổi giá điện theo bậc thang hoặc thay đổi hành vi sinh hoạt đột xuất. Các yếu tố này được xem là hướng mở rộng trong giai đoạn sau.

5. Kết quả mong đợi

- Xây dựng được bộ dữ liệu phụ tải điện theo giờ có đủ đặc trưng thời gian, thời tiết, hành vi và phụ tải trễ.
- Tạo được hai tập dữ liệu cho hai horizon **1h** và **24h**, mỗi horizon có cấu trúc **core** và **extended**.
- Thiết kế và huấn luyện được mô hình ANFIS dạng Sugeno cho bài toán hồi quy phụ tải điện.
- Đánh giá mô hình bằng các độ đo MAE, RMSE, MAPE, MPE và hệ số R^2 .
- Lưu kết quả huấn luyện, dự báo, metrics và biểu đồ theo từng horizon, gồm các nhóm **plots**, **metrics**, **models** và **predictions**.

CHƯƠNG 1. GIỚI THIỆU BÀI TOÁN

1. Đặt vấn đề

Điện năng tiêu thụ trong hộ gia đình thay đổi liên tục theo giờ, theo ngày và theo điều kiện thời tiết. Cùng một hộ gia đình có thể tiêu thụ rất ít điện vào ban đêm, tăng mạnh vào giờ nấu ăn, giờ sinh hoạt buổi tối hoặc những thời điểm nhiệt độ cảm nhận cao khiến thiết bị làm mát hoạt động nhiều hơn. Vì vậy, dự báo phụ tải điện sinh hoạt không chỉ là bài toán ước lượng một giá trị kWh, mà còn là bài toán mô hình hóa quan hệ giữa thời gian, thời tiết, mức hiện diện và lịch sử tiêu thụ điện.

Trong đề tài này, bài toán được xác định là dự báo phụ tải điện hộ gia đình tại hai mốc tương lai: 1 giờ tới và 24 giờ tới. Mốc 1 giờ tới phù hợp với các ứng dụng phản ứng nhanh như cảnh báo tiêu thụ bất thường hoặc gợi ý giảm tải trong ngày. Mốc 24 giờ tới phù hợp với lập kế hoạch cho ngày kế tiếp, ví dụ ước lượng nhu cầu điện theo lịch sinh hoạt và điều kiện thời tiết dự báo.

ANFIS được lựa chọn vì mô hình có thể học quan hệ phi tuyến từ dữ liệu giống mạng nơ-ron, đồng thời vẫn giữ khả năng diễn giải thông qua các luật mờ IF-THEN. Đặc điểm này phù hợp với bài toán phụ tải điện, nơi các khái niệm như “nóng”, “ấm”, “giờ cao điểm” hoặc “mức hiện diện cao” thường không có ranh giới tuyệt đối.

2. Mục tiêu của đề tài

Mục tiêu chính của đề tài gồm:

- Nghiên cứu cơ sở lý thuyết về logic mờ, mạng nơ-ron và hệ suy diễn Neuro-Fuzzy thích nghi ANFIS.
- Xây dựng bài toán dự báo phụ tải điện sinh hoạt theo giờ với hai target `target_1h` và `target_24h`.
- Thiết kế bộ đặc trưng phù hợp cho ANFIS, bao gồm thời tiết, chu kỳ giờ trong ngày, mức hiện diện và phụ tải cách thời điểm hiện tại 24 giờ.
- Tổ chức dữ liệu sau tiền xử lý thành các nhóm `raw`, `scaled`, `core`, `extended` để dễ huấn luyện và mở rộng thí nghiệm.
- Huấn luyện, đánh giá và lưu kết quả mô hình riêng cho hai horizon 1h và 24h.

- Đánh giá mô hình bằng các độ đo hồi quy như MAE, RMSE, MAPE, MPE và hệ số R^2 .

3. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của đề tài là phụ tải điện sinh hoạt theo giờ của hộ gia đình. Phạm vi triển khai tập trung vào dữ liệu tại Hà Nội, trong đó dữ liệu thời tiết được thu thập theo giờ và dữ liệu phụ tải được mô phỏng từ các profile hộ gia đình khác nhau. Các đặc trưng chính gồm nhiệt độ cảm nhận, độ ẩm, chu kỳ giờ trong ngày, mức hiện diện và phụ tải trễ.

Trong phạm vi bài tập lớn, mô hình chưa sử dụng dữ liệu công tơ thực tế và chưa xét đầy đủ các yếu tố như giá điện bậc thang, thay đổi hành vi đột xuất, lịch đi vắng dài ngày hoặc sự cố điện ngoài mô phỏng. Các yếu tố này có thể được bổ sung khi hệ thống có nguồn dữ liệu thực tế phong phú hơn.

4. Phương pháp thực hiện (Workflow)

Workflow chính thức của dự án

Dự án xây dựng hệ thống dự báo phụ tải điện sinh hoạt sử dụng dữ liệu thời tiết thực tế tại Hà Nội, dữ liệu phụ tải mô phỏng và mô hình ANFIS. Quy trình thực hiện gồm các bước chính sau:

1. Thu thập dữ liệu thời tiết

- Sử dụng Open-Meteo API để lấy dữ liệu thời tiết theo giờ tại Hà Nội giai đoạn 2021–2025.
- Các thuộc tính gồm nhiệt độ, độ ẩm, nhiệt độ cảm nhận, lượng mưa, tốc độ gió và độ che phủ mây.
- Kiểm tra dữ liệu thiếu và thực hiện khám phá dữ liệu ban đầu.

2. Xây dựng dữ liệu phụ tải điện

- Xây dựng các profile hộ gia đình với quy mô và thói quen sinh hoạt khác nhau.
- Sinh đặc trưng thời gian như giờ trong ngày, ngày trong tuần, ngày nghỉ, mùa và mã hóa chu kỳ.
- Sinh đặc trưng hành vi như mức hiện diện, hoạt động bữa ăn, giờ làm việc, giờ ngủ.
- Sinh đặc trưng thời tiết như cooling degree, humid hot, rainy hour.

- Mô phỏng phụ tải điện và tạo anomaly/spike.
- Tạo hai nhãn dự báo `target_1h` và `target_24h`.

3. Tiền xử lý dữ liệu

- Làm sạch dữ liệu và loại bỏ giá trị không hợp lệ.
- Kiểm tra missing values và duplicate rows.
- Chia dữ liệu train/test theo thời gian với mốc train kết thúc trước năm 2025.
- Chuẩn hóa dữ liệu bằng Min-Max Scaling, fit scaler trên tập train.
- Tạo nhóm Core Features dành cho ANFIS và nhóm Extended Features dành cho baseline hoặc thí nghiệm mở rộng.
- Lưu dữ liệu vào các nhóm `raw`, `scaled` và `stats` trong thư mục `processed`.

4. Huấn luyện mô hình

- Huấn luyện ANFIS bằng bộ Core Features đã chuẩn hóa.
- Chạy riêng từng horizon 1h và 24h.
- Sử dụng hàm thuộc Gaussian, hệ luật mờ dạng lưới và hệ quả Sugeno bậc nhất.
- Lưu mô hình vào thư mục `results/{horizon}/models/`.

5. Đánh giá và trực quan hóa

- Sử dụng các metrics MAE, RMSE, MAPE, MPE và R^2 .
- Vẽ biểu đồ Actual vs Predicted, phân phối residual và membership functions.
- Lưu metrics, prediction và biểu đồ vào `results/1h/` và `results/24h/`.

6. Kết luận và hướng phát triển

- Đánh giá hiệu quả tổng thể của mô hình.
- Phân tích ưu điểm và hạn chế của ANFIS.
- Đề xuất hướng cải tiến với dữ liệu thực tế EVN, tối ưu fuzzy rules và mở rộng tập đặc trưng.

Workflow tổng quát:

Weather Data Collection → Load Dataset Generation → Data Preprocessing → ANFIS Training → Evaluation & Visualization → Conclusion & Future Work

5. Cấu trúc dữ liệu và kết quả

Để tránh nhầm lẫn giữa hai horizon, dữ liệu và kết quả được tách theo cấu trúc thống nhất:

- Dữ liệu chưa chuẩn hóa: `data/processed/raw/`, gồm `core/` và `extended/`.
- Dữ liệu đã chuẩn hóa: `data/processed/scaled/`, gồm `core/` và `extended/`.
- Thống kê scaler và cấu hình đặc trưng: `data/processed/stats/`.
- Kết quả cho dự báo 1 giờ tới: `results/1h/`.
- Kết quả cho dự báo 24 giờ tới: `results/24h/`.

Trong mỗi thư mục kết quả theo horizon, các artifact được chia tiếp thành `plots`, `metrics`, `models` và `predictions`. Cách tổ chức này giúp quá trình đánh giá, so sánh và tái chạy thí nghiệm rõ ràng hơn.

6. Bố cục báo cáo

Báo cáo gồm các phần chính sau:

- Chương 1 trình bày tổng quan bài toán, mục tiêu, phạm vi và workflow thực hiện.
- Chương 2 trình bày cơ sở lý thuyết về logic mờ, mạng nơ-ron và ANFIS.
- Chương 3 trình bày dữ liệu, thiết kế đặc trưng và quy trình tiền xử lý.
- Chương 4 trình bày thiết kế mô hình ANFIS và quy trình suy diễn.
- Chương 5 trình bày phương pháp thực nghiệm, đánh giá và so sánh mô hình.
- Phần tổng kết trình bày kết luận và định hướng phát triển tiếp theo.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

1. Bài toán dự báo phụ tải điện theo chuỗi thời gian

Dự báo phụ tải điện hộ gia đình là bài toán hồi quy chuỗi thời gian, trong đó mô hình ước lượng điện năng tiêu thụ tại một mốc tương lai dựa trên thông tin đã biết ở thời điểm hiện tại. Gọi $load_t$ là điện năng tiêu thụ tại giờ t , vector đặc trưng đầu vào tại thời điểm t được ký hiệu là $\mathbf{x}_t$.

Trong đề tài này, hệ thống không chỉ dự báo một đầu ra chung mà tách thành hai horizon $h \in \{1h, 24h\}$ nên mô hình cần học:

$$\hat{y}_{(t+1)}^{(h)} = f^{(h)}(\mathbf{x}_t), \quad \hat{y}_{(t+24)}^{(h)} = f^{(h)}(\mathbf{x}_t) \quad (2.1)$$

Trong đó $\hat{y}_{(t+1)}^{(h)}$ là dự báo phụ tải 1 giờ tới, còn $\hat{y}_{(t+24)}^{(h)}$ là dự báo phụ tải 24 giờ tới. Hai bài toán dùng cùng nguyên lý mô hình hóa nhưng có nhãn khác nhau là `target_1h` và `target_24h`. Mốc 1 giờ tới phản ánh khả năng dự báo ngắn hạn gần thời gian thực, còn mốc 24 giờ tới phản ánh khả năng nắm bắt chu kỳ ngày và hỗ trợ lập kế hoạch cho ngày kế tiếp.

2. Đặc trưng đầu vào

Đặc trưng đầu vào cần mô tả được ba nhóm tác động chính tới phụ tải sinh hoạt: điều kiện thời tiết, chu kỳ thời gian và hành vi sử dụng điện. Với mô hình ANFIS, đề tài ưu tiên nhóm Core Features có số chiều vừa phải để tránh số lượng luật mờ tăng quá nhanh.

Đặc trưng	Ý nghĩa
<code>apparent_temperature</code>	Nhiệt độ cảm nhận, phản ánh tác động tổng hợp của thời tiết tới nhu cầu làm mát hoặc sưởi.
<code>humidity</code>	Độ ẩm không khí theo giờ, có thể ảnh hưởng tới cảm giác nóng ẩm và nhu cầu sử dụng thiết bị.
<code>hour_sin, hour_cos</code>	Mã hóa chu kỳ giờ trong ngày bằng sin và cos để mô hình hiểu tính tuần hoàn 24 giờ.
<code>occupancy_level</code>	Mức hiện diện hoặc mức hoạt động của hộ gia đình tại thời điểm quan sát.
<code>load_lag_24</code>	Phụ tải cùng giờ của ngày trước, giúp mô hình học chu kỳ sinh hoạt theo ngày.

Bảng 2.1: Nhóm Core Features dùng cho mô hình ANFIS

Ngoài Core Features, nhóm Extended Features có thể bao gồm lag features,

rolling features, đặc trưng ngày trong tuần, ngày nghỉ, mùa, trạng thái mưa hoặc các biến mô tả profile hộ gia đình. Các đặc trưng mở rộng hữu ích cho thí nghiệm bổ sung hoặc mô hình baseline, nhưng khi đưa vào ANFIS cần cân nhắc vì mỗi biến đầu vào làm tăng số luật mờ và chi phí huấn luyện.

3. Tiền xử lý dữ liệu

Trước khi huấn luyện, dữ liệu cần được kiểm tra missing values, duplicate rows và các điểm anomaly/spike quá bất thường. Với chuỗi thời gian, cách chia train/test phải giữ đúng thứ tự thời gian để tránh rò rỉ thông tin từ tương lai về quá khứ. Trong đề tài, scaler chỉ được fit trên tập train, sau đó áp dụng lại cho cả train và test.

Min-Max Scaling được dùng để đưa các đặc trưng về miền giá trị ổn định:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (2.2)$$

Trong đó $x_{\min}$ và $x_{\max}$ được tính từ tập train. Việc chuẩn hóa giúp các biến như nhiệt độ, độ ẩm, mức hiện diện và phụ tải trễ có thang đo tương đồng hơn khi đi vào mô hình. Dữ liệu sau xử lý được tách thành **raw** và **scaled**, đồng thời chia theo nhóm **core** và **extended**.

4. Logic mờ

Logic mờ cho phép biểu diễn những khái niệm không có ranh giới tuyệt đối như “nóng”, “ấm”, “cao điểm” hoặc “mức hiện diện cao”. Thay vì chỉ thuộc hoặc không thuộc một tập, mỗi giá trị có một độ thuộc nằm trong khoảng $[0, 1]$.

Một hàm thuộc thường dùng trong ANFIS là hàm Gaussian:

$$\mu(x) = \exp\left(-\frac{(x - c)^2}{2\sigma^2}\right) \quad (2.3)$$

Trong đó c là tâm của hàm thuộc và σ điều khiển độ rộng của đường cong. Hàm Gaussian có dạng mợt, phù hợp với các biến liên tục như nhiệt độ cảm nhận, độ ẩm hoặc phụ tải trễ.

Luật mờ có dạng IF-THEN. Ví dụ trong bối cảnh phụ tải hộ gia đình:

Nếu nhiệt độ cảm nhận cao, mức hiện diện cao và phụ tải cùng giờ hôm trước cao thì phụ tải ở mốc dự báo có xu hướng cao.

Các luật như vậy giúp mô hình có khả năng diễn giải tốt hơn so với mạng nơ-ron thuần túy.

5. Mạng nơ-ron và mô hình Neuro-Fuzzy

Mạng nơ-ron nhân tạo có khả năng học quan hệ phi tuyến giữa đầu vào và đầu ra thông qua quá trình tối ưu tham số. Trong bài toán phụ tải điện, quan hệ giữa thời tiết, thời gian, hành vi sinh hoạt và điện năng tiêu thụ thường không tuyến tính, vì vậy mô hình học máy là lựa chọn phù hợp.

Tuy nhiên, mạng nơ-ron thường khó giải thích. Ngược lại, logic mờ dễ diễn giải bằng luật IF-THEN nhưng nếu thiết kế thủ công thì khó tự điều chỉnh tham số theo dữ liệu. Mô hình Neuro-Fuzzy kết hợp hai hướng này: phần mờ biểu diễn tri thức bằng luật, còn phần nơ-ron hỗ trợ học tham số từ dữ liệu.

6. Hệ suy diễn Neuro-Fuzzy thích nghi ANFIS

ANFIS (Adaptive Neuro-Fuzzy Inference System) là mô hình Neuro-Fuzzy dùng kiến trúc nhiều lớp để hiện thực hóa hệ suy diễn mờ. Trong đề tài, ANFIS dạng Sugeno bậc nhất được dùng cho bài toán hồi quy phụ tải điện.

Với một horizon $h \in \{1h, 24h\}$, luật Sugeno thứ i có dạng:

$$R_i : \text{ IF } x_1 \text{ is } A_{i1}, \dots, x_n \text{ is } A_{in} \text{ THEN } f_i^{(h)} = p_{i1}^{(h)} x_1 + \dots + p_{in}^{(h)} x_n + r_i^{(h)} \quad (2.4)$$

Trong đó x_k là đặc trưng đầu vào thứ k , A_{ik} là tập mờ tương ứng, còn $p_{ik}^{(h)}$ và $r_i^{(h)}$ là tham số hệ quả cần học cho horizon h .

6.1. Năm lớp của ANFIS

Lớp 1 – Mờ hóa. Mỗi đầu vào được chuyển thành độ thuộc với các tập mờ:

$$\mu_{A_{ik}}(x_k) = \exp\left(-\frac{(x_k - c_{ik})^2}{2\sigma_{ik}^2}\right) \quad (2.5)$$

Trong đó:

- x_k : biến đầu vào thứ k ;
- A_{ik} : tập mờ thứ i của biến đầu vào x_k ;
- c_{ik} : tâm của hàm thuộc;
- σ_{ik} : tham số điều khiển độ rộng của đường cong (σ_{ik} càng nhỏ, đường cong càng hẹp và dốc; σ_{ik} càng lớn, đường cong càng rộng và phẳng).

Lớp 2 – Lớp luật. Mức kích hoạt của luật i thường được tính bằng tích các độ thuộc:

$$w_i = \prod_{k=1}^n \mu_{A_{ik}}(x_k) \quad (2.6)$$

Lớp 3 – Chuẩn hóa. Mức kích hoạt được chuẩn hóa để tạo trọng số tương đối:

$$\bar{w}_i = \frac{w_i}{\sum_{j=1}^N w_j} \quad (2.7)$$

Trong đó:

- N : tổng số luật mờ trong hệ thống;
- w_i : mức kích hoạt của luật thứ i ;
- $\bar{w}_i$: mức kích hoạt chuẩn hóa của luật thứ i trong quá trình suy diễn;
- $\sum_{j=1}^N w_j$: tổng mức kích hoạt của tất cả các luật, đảm bảo rằng tổng các trọng số chuẩn hóa $\sum_{i=1}^N \bar{w}_i$ bằng 1.

Lớp 4 – Hệ quả Sugeno. Lớp hệ quả Sugeno tính đầu ra cục bộ của từng luật, chưa phải dự báo cuối cùng của mô hình. Mỗi nơ-ron trong lớp này tính giá trị hệ quả $f_i^{(h)}$ của một luật dựa trên mô hình Sugeno bậc nhất:

$$f_i^{(h)} = p_{i1}^{(h)} x_1 + \dots + p_{in}^{(h)} x_n + r_i^{(h)} \quad (2.8)$$

Sau đó, kết quả này được nhân với trọng số chuẩn hóa của luật tương ứng từ lớp chuẩn hóa để tạo ra đầu ra có trọng số:

$$\bar{w}_i f_i^{(h)} = \bar{w}_i (p_{i1}^{(h)} x_1 + \dots + p_{in}^{(h)} x_n + r_i^{(h)}) \quad (2.9)$$

Lớp 5 – Tổng hợp đầu ra. Dự báo cuối cùng là tổng các đầu ra có trọng số:

$$\hat{y}^{(h)} = \sum_{i=1}^N \bar{w}_i f_i^{(h)} \quad (2.10)$$

Trong triển khai thực nghiệm, hai horizon 1h và 24h được huấn luyện và đánh giá riêng. Cách tách này giúp lưu artifact rõ ràng theo `results/1h/` và `results/24h/`, đồng thời cho phép so sánh sai số giữa dự báo rất ngắn hạn và dự báo theo chu kỳ ngày.

7. Các độ đo đánh giá

Vì đầu ra là điện năng tiêu thụ theo đơn vị kWh, mô hình được đánh giá bằng các metrics hồi quy. Với M mẫu kiểm tra, $y_t^{(h)}$ là giá trị thực tế và $\hat{y}_t^{(h)}$ là giá trị dự báo.

7.1. MAE

$$MAE = \frac{1}{M} \sum_{t=1}^M |y_t^{(h)} - \hat{y}_t^{(h)}| \quad (2.11)$$

MAE cho biết trung bình mô hình dự báo lệch bao nhiêu kWh so với thực tế.

7.2. RMSE

$$RMSE = \sqrt{\frac{1}{M} \sum_{t=1}^M (y_t^{(h)} - \hat{y}_t^{(h)})^2} \quad (2.12)$$

RMSE phạt mạnh các sai số lớn, do đó hữu ích khi cần quan sát các lần dự báo lệch nhiều.

7.3. MAPE và MPE

$$MAPE = \frac{100}{M} \sum_{t=1}^M \left| \frac{y_t^{(h)} - \hat{y}_t^{(h)}}{y_t^{(h)}} \right| \quad (2.13)$$

$$MPE = \frac{100}{M} \sum_{t=1}^M \frac{y_t^{(h)} - \hat{y}_t^{(h)}}{y_t^{(h)}} \quad (2.14)$$

MAPE biểu diễn sai số trung bình theo phần trăm, còn MPE cho biết xu hướng dự báo lệch cao hay thấp. Khi dùng hai độ đo này cần đảm bảo $y_t^{(h)}$ khác 0 hoặc có cơ chế xử lý mẫu có giá trị rất nhỏ.

7.4. Hệ số xác định R^2

$$R^2 = 1 - \frac{\sum_{t=1}^M (y_t^{(h)} - \hat{y}_t^{(h)})^2}{\sum_{t=1}^M (y_t^{(h)} - \bar{y})^2} \quad (2.15)$$

R^2 càng gần 1 thì mô hình càng giải thích tốt biến thiên của dữ liệu; nếu $R^2 < 0$, mô hình kém hơn cách dự báo bằng giá trị trung bình.

CHƯƠNG 3. DỮ LIỆU VÀ TIỀN XỬ LÝ DỮ LIỆU

1. Nguồn dữ liệu

CHƯƠNG 4. THIẾT KẾ VÀ TRIỂN KHAI MÔ HÌNH ANFIS

1. Mục tiêu triển khai

Chương này trình bày cách thiết kế và triển khai mô hình ANFIS cho bài toán dự báo phụ tải điện hộ gia đình theo giờ. Khác với hướng dự báo điện năng theo tháng, mô hình trong dự án hiện tại làm việc với chuỗi dữ liệu theo giờ và huấn luyện riêng cho hai mốc dự báo:

- 1h: dự báo phụ tải tại giờ kế tiếp, sử dụng nhãn `target_1h`.
- 24h: dự báo phụ tải cùng giờ của ngày kế tiếp, sử dụng nhãn `target_24h`.

Hai mô hình sử dụng cùng kiến trúc ANFIS Core nhưng tách dữ liệu, scaler, kết quả và artifact theo từng horizon. Cách triển khai này giúp việc đánh giá không bị lẫn giữa dự báo rất ngắn hạn và dự báo theo chu kỳ ngày.

2. Đầu vào, đầu ra và phạm vi mô hình

Mô hình ANFIS sử dụng nhóm Core Features đã được chuẩn hóa bằng Min-Max Scaling. Vector đầu vào tại thời điểm t được ký hiệu là:

$$\mathbf{x}_t = [x_{t,1}, x_{t,2}, \dots, x_{t,6}] \quad (4.1)$$

Trong triển khai hiện tại, thứ tự đặc trưng được giữ cố định để quá trình huấn luyện, lưu mô hình và suy diễn luôn nhất quán.

Thành phần	Mô tả
Đặc trưng đầu vào	<code>apparent_temperature</code> , <code>humidity</code> , <code>hour_sin</code> , <code>hour_cos</code> , <code>occupancy_level</code> , <code>load_lag_24</code> .
Dữ liệu huấn luyện	Các file <code>train_1h.csv</code> , <code>train_24h.csv</code> trong <code>data/processed/scaled/core/</code> .
Dữ liệu kiểm tra	Các file <code>test_1h.csv</code> , <code>test_24h.csv</code> trong <code>data/processed/scaled/core/</code> .
Nhãn dự báo	<code>target_1h</code> cho horizon 1h và <code>target_24h</code> cho horizon 24h.
Đầu ra mô hình	Giá trị phụ tải dự báo. Trong quá trình huấn luyện, đầu ra ở miền scaled; khi đánh giá được chuyển ngược về kWh.

Bảng 4.1: Đầu vào và đầu ra của mô hình ANFIS Core

Dữ liệu `raw` vẫn được giữ để truy xuất giá trị kWh gốc, tính baseline `load_lag_24` và xuất file dự báo để diễn giải. Dữ liệu `scaled` được dùng trực tiếp cho ANFIS nhằm đảm bảo các đặc trưng có miền giá trị ổn định.

3. Kiến trúc mô hình

Mô hình được triển khai theo kiến trúc ANFIS 5 lớp với hàm thuộc Gaussian và hệ quả Sugeno bậc nhất. Cấu hình mặc định của dự án gồm 6 biến đầu vào, 2 hàm thuộc cho mỗi biến và lưới luật đầy đủ.

Tham số	Giá trị triển khai
Số đặc trưng đầu vào	$n = 6$.
Loại hàm thuộc	Gaussian.
Số hàm thuộc mỗi đặc trưng	$m = 2$.
Số luật mờ	$N = m^n = 2^6 = 64$.
Hệ quả luật	Sugeno bậc nhất.
Hệ số Ridge	<code>ridge_alpha</code> = 1e-4.
Seed mặc định	20260527.

Bảng 4.2: Cấu hình ANFIS Core trong dự án

Với đặc trưng đầu vào x_k , độ thuộc vào tập mờ A_{ik} được tính bằng:

$$\mu_{A_{ik}}(x_k) = \exp\left(-\frac{(x_k - c_{ik})^2}{2\sigma_{ik}^2}\right) \quad (4.2)$$

Các tâm c_{ik} được khởi tạo từ phân vị của tập huấn luyện đã chuẩn hóa. Với hai hàm thuộc, mô hình dùng các mức phân vị 25% và 75% để tạo hai vùng đại diện cho giá trị thấp và cao của từng đặc trưng. Tham số σ_{ik} được chọn đủ lớn để tránh hàm thuộc quá hẹp, giúp quá trình suy diễn ổn định hơn.

4. Sinh luật mờ

Do số lượng đặc trưng Core được giới hạn ở 6 biến, dự án sử dụng lưới luật đầy đủ. Mỗi luật là một tổ hợp giữa các hàm thuộc của tất cả biến đầu vào. Nếu mỗi biến có 2 tập mờ, tổng số luật là:

$$N_{\text{rules}} = 2^6 = 64 \quad (4.3)$$

Luật mờ thứ i có dạng tổng quát:

$$R_i : \text{ IF } x_1 \text{ is } A_{i1}, \dots, x_6 \text{ is } A_{i6} \text{ THEN } f_i^{(h)} = p_{i0}^{(h)} + \sum_{k=1}^6 p_{ik}^{(h)} x_k \quad (4.4)$$

Trong đó $h \in \{1h, 24h\}$ là horizon dự báo. Mỗi horizon có bộ tham số hệ quả riêng vì `target_1h` và `target_24h` mô tả hai bài toán khác nhau. Mức kích hoạt của luật được tính bằng tích các độ thuộc:

$$w_i = \prod_{k=1}^6 \mu_{A_{ik}}(x_k) \quad (4.5)$$

Sau đó các mức kích hoạt được chuẩn hóa:

$$\bar{w}_i = \frac{w_i}{\sum_{j=1}^N w_j} \quad (4.6)$$

Dự báo cuối cùng của mô hình là tổng có trọng số của các hệ quả Sugeno:

$$\hat{y}^{(h)} = \sum_{i=1}^N \bar{w}_i f_i^{(h)} \quad (4.7)$$

5. Huấn luyện mô hình

Quy trình huấn luyện được triển khai trong nhóm module mô hình của dự án. Tập tin `anfis.py` chứa phần lõi ANFIS, còn `trainer.py` điều phối huấn luyện và lưu model artifact. Phần lõi ANFIS chịu trách nhiệm tính hàm thuộc, mức kích hoạt, chuẩn hóa luật và suy diễn. Entrypoint CLI chạy thực nghiệm theo từng horizon, sau đó gọi `trainer` để khởi tạo mô hình, fit tham số hệ quả và ghi artifact.

Dữ liệu train được chia thêm thành `train_fit` và `validation`. Trong cấu hình hiện tại, `validation` bắt đầu từ mốc 2024-01-01; tập test là dữ liệu năm 2025 đã được tách từ bước tiền xử lý. Việc chia theo thời gian giúp đánh giá đúng hơn cho bài toán chuỗi thời gian.

Các bước huấn luyện cho một horizon gồm:

1. Nạp dữ liệu Core đã chuẩn hóa từ `data/processed/scaled/core/`.
2. Nạp dữ liệu raw tương ứng và các file scaler stats từ `data/processed/stats/`.
3. Tách phần train thành `train_fit` và `validation` theo mốc thời gian.
4. Khởi tạo hàm thuộc Gaussian từ phân vị của `train_fit`.
5. Tạo ma trận thiết kế Sugeno từ các trọng số luật đã chuẩn hóa.
6. Fit tham số hệ quả bằng Ridge least squares.
7. Tính RMSE trên miền scaled cho train và validation.
8. Lưu mô hình và metadata vào `results/{horizon}/models/`.

Thay vì tối ưu toàn bộ tham số bằng nhiều epoch lan truyền ngược, phiên bản hiện tại fit hệ quả Sugeno bằng Ridge. Cách này phù hợp với phạm vi bài tập lớn vì ổn định, dễ kiểm soát và cho phép lưu lại mô hình dưới dạng các ma trận NumPy.

6. Suy diễn và chuyển ngược đơn vị

Trong giai đoạn suy diễn, mô hình nhận vector đặc trưng Core ở miền scaled và trả về dự báo scaled. Kết quả này được chuyển ngược về kWh bằng thống kê scaler của target:

$$\hat{y}_{\text{kWh}} = \hat{y}_{\text{scaled}} \times \text{range}_y + \text{min}_y \quad (4.8)$$

Trong đó min_y và range_y được lấy từ file `target_scaler_stats` tương ứng với từng horizon. Việc chuyển ngược đơn vị là cần thiết để metrics, prediction file và biểu đồ có ý nghĩa thực tế.

File dự báo trên tập test gồm các cột chính:

- `datetime`, `profile_code`, `profile_name`: thông tin thời gian và profile hộ gia đình.
- `actual_kwh`: phụ tải thực tế tại horizon cần dự báo.
- `predicted_kwh`: phụ tải do ANFIS dự báo.
- `baseline_lag24_kwh`: dự báo baseline dùng `load_lag_24`.
- `error_kwh`, `abs_error_kwh`, `ape`: các sai số phục vụ đánh giá.

7. Đánh giá và lưu artifact

Sau khi huấn luyện, mỗi horizon được đánh giá trên tập test bằng các metrics hồi quy như MAE, RMSE, MAPE và R^2 . Ngoài ANFIS, pipeline còn tính baseline Lag-24 từ `load_lag_24` để có mốc so sánh đơn giản. Baseline này đặc biệt quan trọng vì phụ tải sinh hoạt có tính chu kỳ theo ngày rất rõ.

Toàn bộ kết quả được lưu riêng theo horizon. Mỗi thư mục kết quả theo horizon có các nhóm artifact sau:

Thư mục	Nội dung
<code>models/</code>	File mô hình ANFIS dạng <code>.npz</code> .
<code>metrics/</code>	Metrics JSON/CSV, training log và cấu hình chạy.
<code>predictions/</code>	File CSV chứa giá trị thực tế, dự báo, baseline và sai số.
<code>plots/</code>	Biểu đồ Actual vs Predicted, phân phối residual và membership functions.

Bảng 4.3: Cấu trúc artifact sau huấn luyện

Cách tổ chức artifact này giúp mỗi lần chạy có thể truy vết lại dữ liệu, tham số mô hình, metrics và biểu đồ tương ứng. Khi cần so sánh nhiều thí nghiệm, chỉ cần đối chiếu các file `config.json`, `metrics.json` và `training_log.csv` theo `run_id`.

Algorithm 1 Quy trình dự báo phụ tải điện bằng ANFIS cho hai horizon.

Input: dữ liệu thời tiết theo giờ, profile hộ gia đình, dữ liệu phụ tải mô phỏng, Core Features, target_1h, target_24h.

Output: mô hình ANFIS, metrics, predictions và plots cho results/1h/ và results/24h/.

```
horizons = [1h, 24h]
core_features = [apparent_temperature, humidity, hour_sin,
                 hour_cos, occupancy_level, load_lag_24]

-- Data preparation and feature engineering --
# collect weather, build profiles and create hourly load series
weather = load_hourly_weather(Hanoi, 2021-2025)
profiles = build_household_profiles()
data = simulate_hourly_load(weather, profiles)
data = inject_anomaly_and_spike(data)
data = check_missing_values_and_duplicate_rows(data)
# create lag features, rolling features and forecast targets
data = create_lag_and_rolling_features(data)
data[target_1h] = shift(load_kwh, -1)
data[target_24h] = shift(load_kwh, -24)

-- Preprocessing per horizon --
for horizon in horizons:
    # fit scalers on train only to avoid leakage
    target = target_columns[horizon]
    train, test = split_by_time(data, train_end=2025-01-01)
    feature_scaler = fit_minmax_scaler(train[core_features])
    target_scaler = fit_minmax_scaler(train[target])
    save_raw_and_scaled_core_extended(train, test, horizon)

-- ANFIS training --
for horizon in horizons:
    # train one ANFIS model for each forecast horizon
    X_train, y_train = load_scaled_core_train(horizon)
    X_test, y_test = load_scaled_core_test(horizon)
    model = ANFIS(n_mfs=2, mf=Gaussian, rules=2^6)
    model.initialize_memberships(X_train)
    model.fit_sugeno_consequents(X_train, y_train, Ridge)

-- Evaluation and artifact export --
# convert predictions to kWh and save reproducible artifacts
pred_scaled = model.predict(X_test)
pred_kwh = inverse_target_scaler(pred_scaled, horizon)
metrics = evaluate(actual_kwh, pred_kwh, baseline=load_lag_24)
save(model, metrics, predictions, plots, horizon)
return results/1h and results/24h artifacts
```

Bảng 4.4: Pseudocode quy trình triển khai đề tài

CHƯƠNG 5. THỰC NGHIỆM VÀ ĐÁNH GIÁ MÔ HÌNH

TỔNG KẾT

Đề tài đã xây dựng khung nghiên cứu và triển khai hệ Neuro-Fuzzy thích nghi ANFIS cho bài toán dự báo điện năng tiêu thụ hộ gia đình. Hệ thống được định hướng theo cách người dùng chỉ cần cung cấp thông tin tối thiểu, bao gồm số điện tháng trước, số người và danh sách thiết bị điện. Các thông tin còn lại như thời gian, vị trí và thời tiết được hệ thống tự động bổ sung để tạo bộ đặc trưng đầu vào cho mô hình.

Về mặt mô hình, ANFIS dạng Sugeno được lựa chọn do phù hợp với bài toán hồi quy và có khả năng giải thích thông qua luật mờ. Báo cáo cũng đề xuất quy trình tiền xử lý dữ liệu, thiết kế tập mờ, sinh luật, huấn luyện, đánh giá và triển khai mô hình trong một ứng dụng thực tế.

Trong giai đoạn tiếp theo, nhóm cần hoàn thiện bộ dữ liệu thực nghiệm, cài đặt mô hình, huấn luyện với nhiều kịch bản đặc trưng và so sánh kết quả với các mô hình học máy khác. Ngoài ra, hệ thống có thể được mở rộng bằng cách cá nhân hóa theo lịch sử sử dụng điện của từng hộ gia đình và tích hợp dự báo chi phí tiền điện.

TÀI LIỆU THAM KHẢO

- [1] L. A. Zadeh, “Fuzzy Sets,” *Information and Control*, vol. 8, no. 3, pp. 338–353, 1965, doi: [https://doi.org/10.1016/S0019-9958\(65\)90241-X](https://doi.org/10.1016/S0019-9958(65)90241-X).
- [2] T. Takagi and M. Sugeno, “Fuzzy Identification of Systems and Its Applications to Modeling and Control,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. SMC-15, no. 1, pp. 116–132, 1985, doi: <https://doi.org/10.1109/TSMC.1985.6313399>.
- [3] J.-S. R. Jang, “ANFIS: Adaptive-Network-Based Fuzzy Inference System,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 23, no. 3, pp. 665–685, 1993, doi: <https://doi.org/10.1109/21.256541>.
- [4] S. Haykin, *Neural Networks and Learning Machines*, 3rd ed. Upper Saddle River, NJ, USA: Pearson, 2009.
- [5] T. Hong and S. Fan, “Probabilistic Electric Load Forecasting: A Tutorial Review,” *International Journal of Forecasting*, vol. 32, no. 3, pp. 914–938, 2016, doi: <https://doi.org/10.1016/j.ijforecast.2015.11.011>.
- [6] R. J. Hyndman and A. B. Koehler, “Another Look at Measures of Forecast Accuracy,” *International Journal of Forecasting*, vol. 22, no. 4, pp. 679–688, 2006, doi: <https://doi.org/10.1016/j.ijforecast.2006.03.001>.
- [7] Open-Meteo, “Historical Weather API,” Open-Meteo.com. [Online]. Available: <https://open-meteo.com/en/docs/historical-weather-api>. Accessed: Jun. 6, 2026.
- [8] Tập đoàn Điện lực Việt Nam, “Trang thông tin điện tử tổng hợp EVN.” [Online]. Available: <https://www.evn.com.vn/>. Accessed: Jun. 6, 2026.
- [9] F. Pedregosa *et al.*, “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [10] C. R. Harris *et al.*, “Array Programming with NumPy,” *Nature*, vol. 585, pp. 357–362, 2020, doi: <https://doi.org/10.1038/s41586-020-2649-2>.
- [11] W. McKinney, “Data Structures for Statistical Computing in Python,” in *Proceedings of the 9th Python in Science Conference*, Austin, TX, USA, 2010, pp. 56–61.

- [12] J. D. Hunter, “Matplotlib: A 2D Graphics Environment,” *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007, doi: <https://doi.org/10.1109/MCSE.2007.55>.

DANH MỤC THUẬT NGỮ VÀ VIẾT TẮT

Mô hình và phương pháp

Thuật ngữ / viết tắt	Ý nghĩa trong đề tài
ANFIS	Adaptive Neuro-Fuzzy Inference System – hệ suy diễn Neuro-Fuzzy thích nghi dùng để dự báo phụ tải điện.
Neuro-Fuzzy	Hướng tiếp cận kết hợp mạng nơ-ron với logic mờ để vừa học từ dữ liệu vừa giữ khả năng diễn giải.
Mạng nơ-ron	Neural network – mô hình học ánh xạ phi tuyến giữa đặc trưng đầu vào và phụ tải đầu ra.
Sugeno	Dạng hệ suy diễn mờ có hệ quả là hàm tuyến tính hoặc hằng số, phù hợp với bài toán hồi quy.
Gaussian	Hàm thuộc dạng chuông được dùng để mờ hóa đặc trưng đầu vào trong ANFIS.
Vector	Tập hợp đặc trưng đầu vào tại một thời điểm, ký hiệu thường dùng là $\mathbf{x}_t$.

Đặc trưng dữ liệu và nhãn dự báo

Thuật ngữ / viết tắt	Ý nghĩa trong đề tài
apparent_temperature	Nhiệt độ cảm nhận, phản ánh tác động tổng hợp của thời tiết tới nhu cầu sử dụng điện.
humidity	Độ ẩm không khí theo giờ, dùng làm đặc trưng thời tiết.
hour_sin	Thành phần sin của mã hóa chu kỳ giờ trong ngày.
hour_cos	Thành phần cos của mã hóa chu kỳ giờ trong ngày.
occupancy_level	Mức hiện diện hoặc mức hoạt động của hộ gia đình tại thời điểm quan sát.
load_lag_24	Phụ tải tại thời điểm cách hiện tại 24 giờ, dùng để nắm chu kỳ theo ngày.
Lag features	Nhóm đặc trưng trễ được tạo từ phụ tải trong quá khứ, ví dụ load_lag_1 và load_lag_24.
Rolling features	Nhóm đặc trưng thống kê trượt theo cửa sổ thời gian, ví dụ trung bình phụ tải 3 giờ hoặc 24 giờ.
target_1h	Nhãn đầu ra cho bài toán dự báo phụ tải 1 giờ tới.
target_24h	Nhãn đầu ra cho bài toán dự báo phụ tải 24 giờ tới.
Profile	Hồ sơ hộ gia đình mô phỏng, mô tả quy mô và thói quen sử dụng điện.
EVN	Tập đoàn Điện lực Việt Nam; trong báo cáo được nhắc như nguồn dữ liệu thực tế tiềm năng ở hướng phát triển.

Tiền xử lý và cấu trúc dữ liệu

Thuật ngữ / viết tắt	Ý nghĩa trong đề tài
Train/Test	Cách chia dữ liệu thành tập huấn luyện và tập kiểm tra theo trục thời gian.
Min-Max Scaling	Phương pháp chuẩn hóa dữ liệu về miền giá trị cố định dựa trên giá trị nhỏ nhất và lớn nhất của tập huấn luyện.
Fit scaler	Bước học tham số scaler trên tập train trước khi áp dụng cho train/test.
Raw	Dữ liệu chưa chuẩn hóa, giữ đơn vị và miền giá trị gốc.
Scaled	Dữ liệu đã chuẩn hóa để đưa vào mô hình.
Core	Nhóm đặc trưng cốt lõi dùng trực tiếp cho ANFIS.
Extended	Nhóm đặc trưng mở rộng dùng cho mô hình so sánh hoặc thí nghiệm bổ sung.
Missing values	Các giá trị bị thiếu trong dữ liệu cần được kiểm tra và xử lý trước khi huấn luyện.
Duplicate rows	Các dòng dữ liệu trùng lặp cần được phát hiện để tránh làm sai lệch tập huấn luyện.

Quy trình và phạm vi dự báo

Thuật ngữ / viết tắt	Ý nghĩa trong đề tài
Workflow	Luồng xử lý tổng thể từ thu thập dữ liệu, sinh phụ tải, tiền xử lý, huấn luyện đến đánh giá.
Horizon	Mốc thời gian dự báo trong tương lai, gồm 1h và 24h.
Anomaly/spike	Điểm bất thường hoặc tăng đột biến trong chuỗi phụ tải được mô phỏng để gần với hành vi thực tế.

Artifact và kết quả đầu ra

Thuật ngữ / viết tắt	Ý nghĩa trong đề tài
Artifact	File hoặc sản phẩm đầu ra của pipeline, ví dụ model, metrics, biểu đồ và prediction.
Metrics	Các chỉ số đánh giá mô hình như MAE, RMSE, MAPE, MPE và R^2 .
Plots	Nhóm biểu đồ trực quan hóa kết quả dự báo và sai số.
Models	Nhóm file lưu tham số hoặc cấu hình mô hình sau huấn luyện.
Predictions	Nhóm file lưu giá trị dự báo và giá trị thực tế trên tập kiểm tra.
File	Đơn vị lưu trữ artifact, thường ở định dạng CSV, JSON, NPZ hoặc PNG.